

Université Côte d'Azur – École Marocaine des Sciences de l'Ingénieur



**ECOLE MAROCAINE DES
SCIENCES DE L'INGENIEUR**
Membre de **HONORIS UNITED UNIVERSITIES**

RAPPORT DE PROJET DE FIN D'ÉTUDES

Master MIAGE : MBDS

5ème Année en Ingénierie Informatique et Réseaux

Année universitaire : 2025 / 2026

Stratégie Data-Driven pour augmenter le volume et la fréquence d'usage des cartes de paiement

Réalisé par :

Hamza Raji

Sous la direction de :

Cherkaoui LEGHRIS
Wassim TAHIR

Encadrant Académique
Encadrant Entreprise

Entreprise d'accueil



التجاري وفا بنك
Attijariwafa bank

Dédicace

Je dédie ce travail à

Mes chers parents,
*dont l'amour inconditionnel,
les sacrifices et le soutien indéfectible
m'ont porté tout au long de ce parcours.
Que Dieu vous accorde longue vie et santé
pour continuer à illuminer mon chemin.*

Mon frère,
*pour son soutien,
son affection et sa présence inestimable
qui m'a donné la force d'avancer
avec confiance et détermination.
Que Dieu lui accorde succès et réussite.*

Ma famille,
*pour leur présence chaleureuse,
leurs encouragements sincères
et leur soutien de chaque instant.
Je vous dois une part de cette réussite.*

Mes amis,
*véritables compagnons de route,
pour leurs encouragements constants
et leur soutien précieux.
Je vous souhaite à tous réussite et épanouissement
dans vos projets.*

Mon chat,
*pour m'avoir fait comprendre, à sa façon,
des choses qu'aucun humain n'aurait pu m'apprendre –
la responsabilité, la patience
et l'amour inconditionnel.*

Avec toute ma gratitude et mon affection.

Remerciements

Je n'aurais jamais pu réaliser ce projet sans la précieuse aide et sans le soutien d'un grand nombre de personnes dont la générosité, la bonne humeur et l'intérêt manifestés à l'égard de mon PFE m'ont permis de progresser.

En premier lieu, je tiens à remercier mon encadrant universitaire **Cherkaoui Leghris**, pour la confiance qu'il m'a accordée en acceptant d'encadrer ce travail, pour ses multiples conseils et pour toutes les heures qu'il a consacrées à diriger ce travail.

Je souhaiterais exprimer ma gratitude à **Wassim Tahir**, pour m'avoir donné envie de réaliser un mémoire sur l'exploitation des données comportementales pour augmenter l'usage des cartes de paiement au sein de « AttijariWafa Bank ». Je le remercie également pour son accueil chaleureux à chaque fois que j'ai sollicité son aide, ainsi que pour ses multiples encouragements. J'ai été extrêmement sensible à ses qualités humaines d'écoute et de compréhension tout au long de ce travail de mémoire.

Je remercie également **Marouane El Allali**, Manager de l'entité Data BDME, pour m'avoir accueilli au sein de son équipe et permis de réaliser ce stage dans les meilleures conditions.

Mes remerciements vont aussi à **Mohammed Mestari**, qui a accepté de m'aider en me transmettant le plan de cadrage ayant servi de point de départ à ce projet, et dont l'intérêt manifesté à l'égard de ce travail a été précieux. J'aimerais enfin dire à Mr Michel SYSKA à quel point je suis honoré pour avoir accepté de présider ce jury de PFE.

Ma reconnaissance va à ceux qui ont plus particulièrement assuré le soutien affectif de ce travail : ma famille ainsi que mes amis. Mes parents, mon frère, en particulier.

Résumé

Ce travail s'inscrit dans le cadre du projet de fin d'études réalisé au sein de l'entité Data BDME de AttijariWafa Bank en vue de l'obtention du diplôme national d'ingénieur à l'École Marocaine des Sciences de l'Ingénieur, en partenariat avec Université Côte d'Azur (Master MIAE – MBDS). L'objectif est de concevoir et mettre en œuvre une stratégie data-driven visant à augmenter le volume et la fréquence d'usage des cartes bancaires pour les paiements, au sein du portefeuille clients de la banque.

Face à l'écart persistant entre le nombre de clients détenteurs d'une carte et ceux qui l'utilisent effectivement pour payer, ce mémoire mobilise, selon la méthodologie CRISP-DM, une démarche analytique construite à partir de deux populations complémentaires – les clients déjà actifs sur le paiement carte et ceux qui ne l'ont jamais utilisé. Une segmentation comportementale par règles métier est d'abord construite pour chaque population, puis validée et enrichie par des méthodes non supervisées (K-Means, DBSCAN, réduction de dimension par PCA et UMAP). Cette base sert ensuite à cinq modèles prédictifs complémentaires : une étude rétrospective de la vitesse d'activation et de la fidélité qui lui est associée, un classifieur XGBoost distinguant les clients actifs des jamais-actifs (AUC de 0,966), un modèle de régression estimant la valeur d'usage attendue de chaque client, un scoring des commerçants partenaires selon la qualité de la clientèle qu'ils attirent, et deux modèles de survie de Cox – l'un estimant le délai avant la première activation, l'autre le risque de désengagement des clients déjà actifs.

L'ensemble de ces résultats se traduit en six recommandations opérationnelles concrètes, offrant à la banque un dispositif d'aide à la décision pour prioriser ses actions commerciales, personnaliser ses campagnes selon le profil des clients et prévenir le désengagement des clients les plus exposés.

Mots clés — *Science des données, Apprentissage automatique, Segmentation comportementale, K-Means, DBSCAN, Réduction de dimension (PCA, UMAP), XGBoost, Régression, Modèle de survie de Cox, Analyse de survie, Scoring commerçant, Désengagement client, Cartes bancaires, Stratégie data-driven, CRISP-DM, Attijariwafa Bank.*

Abstract

This work is part of the graduation project carried out within the Data BDME entity of AttijariWafa Bank , in order to obtain the national engineering diploma from the École Marocaine des Sciences de l'Ingénieur, in partnership with Université Côte d'Azur (MIAGE Master's – MBDS). The objective is to design and implement a data-driven strategy aimed at increasing the volume and frequency of bank card usage for payments within the bank's client portfolio.

Given the persistent gap between clients who own a bank card and those who actually use it for payments, this thesis follows the CRISP-DM methodology to build an analytical approach based on two complementary populations – clients already active in card payments and those who have never used one. A rule-based behavioral segmentation is first built for each population, then validated and enriched through unsupervised methods (K-Means, DBSCAN, dimensionality reduction via PCA and UMAP). This foundation supports five complementary predictive models : a retrospective study of activation speed and the resulting customer loyalty, an XGBoost classifier distinguishing active from never-active clients (AUC of 0.966), a regression model estimating each client's expected usage value, a merchant scoring system based on the quality of the clientele they attract, and two Cox survival models – one estimating the time to first activation, the other the risk of disengagement among already-active clients.

These results translate into six concrete operational recommendations, providing the bank with a decision-support framework to prioritize commercial actions, personalize campaigns according to client profile, and prevent disengagement among the most at-risk clients.

Keywords— *Data Science, Machine Learning, Behavioral Segmentation, K-Means, DBSCAN, Dimensionality Reduction (PCA, UMAP), XGBoost, Regression, Cox Survival Model, Survival Analysis, Merchant Scoring, Customer Churn, Bank Cards, Data-Driven Strategy, CRISP-DM, Attijariwafa Bank.*

ملخص

يندرج هذا العمل ضمن مشروع نهاية الدراسات المنجز داخل كيان BDME Data التابع لمجموعة التجاري وفا بنك (AttijariWafa Bank)، وذلك بغرض الحصول على دبلوم المهندس الوطني من المدرسة المغربية لعلوم المهندس (EMSI)، في إطار شراكة مع جامعة كوت دازور (Université Côte d'Azur) -- ماستر MIAGE - MBDS. يهدف هذا المشروع إلى تصميم وتنفيذ استراتيجية قائمة على البيانات (data-driven) لزيادة حجم وتواتر استخدام البطاقات البنكية في عمليات الأداء، ضمن محفظة عملاء البنك.

نظرا للفجوة القائمة بين عدد العملاء الحائزين على بطاقة بنكية وأولئك الذين يستخدمونها فعليا للأداء، تعتمد هذه المذكرة، وفق منهجية CRISP-DM مقارنة تحليلية مبنية على مجموعتين متكاملتين من العملاء -- العملاء النشطين بالفعل في الأداء بالبطاقة، وأولئك الذين لم يستخدموها قط. يتم أولا بناء تصنيف سلوكي قائم على قواعد العمل لكل مجموعة، ثم يتم التحقق من صحته وإثراؤه بواسطة طرق غير موجهة (K-Means، DBSCAN، وتقليص الأبعاد باستخدام PCA وUMAP). تُستخدم هذه القاعدة بعد ذلك في خمسة نماذج تنبؤية متكاملة : دراسة استرجاعية لسرعة التفعيل والولاء المرتبط بها، ونموذج تصنيف XGBoost يميز بين العملاء النشطين وغير النشطين على الإطلاق (بدقة AUC تبلغ 966.0)، ونموذج انحدار يقدر القيمة المتوقعة لاستخدام كل عميل، ونظام لتصنيف التجار الشركاء حسب جودة العملاء الذين يجذبونهم، ونموذجي بقاء من نوع Cox -- يقدر أحدهما المدة قبل التفعيل الأول، ويقدر الآخر خطر انقطاع العملاء النشطين بالفعل عن الاستخدام.

تُترجم كل هذه النتائج إلى ست توصيات عملية ملموسة، توفر للبنك أداة لدعم اتخاذ القرار من أجل ترتيب أولويات الإجراءات التجارية، وتخصيص الحملات حسب ملف كل عميل، والوقاية من انقطاع العملاء الأكثر عرضة لذلك.

الكلمات المفتاحية -- علم البيانات، التعلم الآلي، التصنيف السلوكي، K-Means، DBSCAN، تقليص الأبعاد (PCA وUMAP)، XGBoost، الانحدار، نموذج البقاء لوكوكس (Cox)، تحليل البقاء، تصنيف التجار، انقطاع العملاء، البطاقات البنكية، الاستراتيجية القائمة على البيانات، CRISP-DM، التجاري وفا بنك.

Table des matières

Dédicace.....	i
Remerciements	ii
Résumé.....	ii
Table des figures	iv
Liste des tableaux	v
Liste des abréviations	vi
Introduction générale	1
Chapitre 1. Présentation du cadre de projet	3
1.1 Cadre académique du projet	4
1.2 Présentation de l'organisme d'accueil	4
1.3 Étude de l'existant	5
1.3.1 Description de l'existant	5
1.3.2 Critique de l'existant	6
1.3.3 Solution proposée	6
1.4 Choix du modèle de développement	7
1.5 Planning prévisionnel	8
Chapitre 2. Spécification des besoins	10
2.1 Besoins fonctionnels	11
2.1.1 Gestion et préparation des données	11
2.1.2 Analyse descriptive et segmentation	11
2.1.3 Préparation des variables analytiques	11
2.1.4 Modélisation prédictive	11
2.1.5 Restitution et pilotage	12
2.2 Besoins non fonctionnels	12
2.2.1 Performance	12
2.2.2 Sécurité	12
2.2.3 Disponibilité	12
2.2.4 Maintenabilité	12
2.2.5 Ergonomie et lisibilité	13
2.3 Modélisation des cas d'utilisation	13
2.3.1 Vue d'ensemble	13
2.3.2 Zoom sur l'entraînement des modèles prédictifs	13

Chapitre 3. Compréhension et préparation des données.	15
3.1 Présentation des tables	16
3.2 Contrôles de cohérence et qualité	20
3.2.1 Nettoyage de la première table client	20
3.2.2 Nettoyage de la deuxième table client	21
3.3 Bilan du nettoyage des deux tables	21
Chapitre 4. Construction de la base analytique	23
4.1 Choix de la granularité des tables	24
4.2 Définition des variables cible	25
4.2.1 Modèle d'activation	25
4.2.2 Modèle d'activation J30	27
4.2.3 Modèle de classification actif / jamais actif	28
4.2.4 Délai avant activation ou désengagement	29
4.2.5 Classification des freins à l'usage	30
4.2.6 Scoring commerçant	30
Chapitre 5. Segmentation comportementale	32
5.1 Cadre méthodologique de la segmentation	33
5.1.1 Pourquoi segmenter, et pourquoi par règles métier	33
5.1.2 Deux tables, deux logiques d'analyse	33
5.2 Construction de la segmentation de la table 1	34
5.2.1 Objectif	34
5.2.2 Variables retenues	34
5.2.3 Construction des scores et des seuils	35
5.2.4 Segmentation principale : paiement et cash	36
5.2.5 Segmentation renforcée	38
5.3 Construction de la segmentation de la table 2	39
5.3.1 Objectif	39
5.3.2 Variables retenues et logique de potentiel	39
5.3.3 Construction du score de potentiel d'activation	39
5.3.4 Segmentation principale	39
5.3.5 Segmentation renforcée	40
5.4 Analyse comparative des deux segmentations	40
5.4.1 Forces et limites de la segmentation métier	41
5.4.2 Segmentation RFM	41
5.5 Ouverture vers les méthodes complémentaires	41
5.5.1 Pourquoi enrichir la lecture métier	41
5.5.2 Méthodes retenues	41
5.5.3 Résultats du clustering K-Means sur la première table	42
5.5.4 Détection des comportements atypiques par DBSCAN sur la première table	43
5.5.5 Résultats du clustering K-Means sur la deuxième table	45
5.5.6 Détection des comportements atypiques par DBSCAN sur la deuxième table	48
Chapitre 6. Étude de la vitesse d'activation et de la fidélité	51
6.1 Populations comparées	52
6.2 Résultats	52
6.3 Désengagement réel par groupe de vitesse d'activation	54

6.4	Commerçant principal selon la vitesse d'activation	54
6.5	Profils au sein de l'activation tardive	54
6.6	Interprétation et limites	56
Chapitre 7.	Modélisation prédictive et recommandations.	57
7.1	Modèle de classification actif / jamais actif	58
7.1.1	Rappel du protocole	58
7.1.2	Résultats	58
7.1.3	Importance des variables	60
7.2	Modèle de régression – valeur attendue	60
7.2.1	Rappel du protocole	60
7.2.2	Résultats	61
7.2.3	Score de valeur attendue et priorisation combinée	61
7.2.4	Limites	62
7.3	Scoring commerçant	63
7.3.1	Rappel de la méthode	63
7.3.2	Résultats	63
7.3.3	Interprétation et usage	64
7.4	Modèle de survie – délai avant première activation	65
7.4.1	Rappel du protocole	65
7.4.2	D'un modèle simple à un modèle stratifié	65
7.4.3	Résultats	66
7.4.4	Limites	66
7.5	Modèle de survie – désengagement réel	67
7.5.1	Rappel du protocole	67
7.5.2	D'un modèle exploratoire à un modèle affiné	68
7.5.3	Résultats	68
7.5.4	Limites	68
7.6	Recommandations stratégiques	69
7.6.1	Prioriser l'activation par un score combiné probabilité $\times$ valeur	69
7.6.2	Accompagner les nouveaux clients dans le premier mois	70
7.6.3	Cibler les partenariats commerçants à forte valeur de clientèle	70
7.6.4	Différencier les actions par segment comportemental	70
7.6.5	Adapter la communication aux profils démographiques et géographiques	70
7.6.6	Prévenir le désengagement selon le niveau de service	71
	Conclusion générale & Perspectives	73
	Bibliographie	76

Table des figures

1.1	Établissements partenaires du double diplôme : Master MIAGE – MBDS (Université Côte d’Azur) et École Marocaine des Sciences de l’Ingénieur	4
1.2	Logo d’Attijariwafa bank, organisme d’accueil de ce projet de fin d’études	5
1.3	Les six phases du modèle CRISP-DM	7
1.4	Planning prévisionnel	8
2.1	Diagramme de cas d’utilisation – vue d’ensemble du dispositif analytique	14
2.2	Diagramme de cas d’utilisation – détail du cas « Entraîner les modèles prédictifs » . .	14
5.1	Distribution des scores et seuils de segmentation retenus	37
5.2	Matrice croisée des segments : Score de paiement $\times$ Score de cash	37
5.3	Répartition des sous-segments de paiement fort	38
5.4	Projection PCA des quatre clusters K-Means (table 1)	44
5.5	Projection UMAP des quatre clusters K-Means (table 1)	44
5.6	Graphe des k-distances et sélection du paramètre eps pour DBSCAN	45
5.7	Clusters denses et comportements atypiques détectés par DBSCAN (projection PCA)	46
5.8	Projection PCA des cinq clusters K-Means (table 2)	47
5.9	Projection UMAP des cinq clusters K-Means (table 2)	47
5.10	Graphe des k-distances et sélection du paramètre eps pour DBSCAN (table 2)	49
5.11	Clusters denses et comportements atypiques détectés par DBSCAN (table 2, projection PCA)	49
6.1	Part de clients « Grand utilisateur multi-usage » selon la vitesse d’activation	53
6.2	Rythme de paiement mensuel depuis l’activation, selon la vitesse d’activation	53
6.3	DBSCAN restreint au groupe « activation tardive » (table 1)	55
7.1	Matrice de confusion du modèle actif / jamais actif (jeu de test)	59
7.2	Courbe ROC du modèle actif / jamais actif	59
7.3	Importance des variables du modèle actif / jamais actif	60
7.4	Valeurs prédites contre valeurs réelles du rythme de paiement mensuel (jeu de test) .	62
7.5	Importance des variables du modèle de régression – valeur attendue	63
7.6	Top 10 des commerçants (échantillon fiable) par part de « Grands utilisateurs multi-usage »	64
7.7	Modèle de survie – variables au plus fort effet sur la vitesse d’activation	67
7.8	Modèle de survie – désengagement réel (marché particulier), variables significatives . .	69

Liste des tableaux

3.1	Identification du client	16
3.2	Ancienneté et dates de relation	16
3.3	Profil socio-démographique	17
3.4	Positionnement bancaire	17
3.5	Paiements locaux et internationaux	17
3.6	Retraits GAB	17
3.7	Activité sur l'application	17
3.8	Crédits et débits	18
3.9	Paiements totaux	18
3.10	Répartition de l'activité	18
3.11	Identification du client	18
3.12	Activité CMC	19
3.13	Activité CMD	19
3.14	Profil socio-démographique	19
3.15	Relation bancaire	19
3.16	Usage digital	20
5.1	Variables retenues pour la segmentation de la table 1 et justification de leur choix . .	35
5.2	Construction des scores utilisés pour la segmentation de la table 1	36
6.1	Désengagement réel (seuil de 120 jours) selon la vitesse d'activation	54

Liste des abréviations

Abréviation	Signification
ARI	Adjusted Rand Index – indice de stabilité d'un partitionnement entre plusieurs exécutions.
AUC	Area Under the Curve – aire sous la courbe ROC, mesure de performance d'un modèle de classification.
BDME	Big Data & Marketing Engineering – entité d'Attijariwafa bank d'accueil de ce PFE.
CRISP-DM	Cross-Industry Standard Process for Data Mining – méthodologie de référence des projets de data science.
DBSCAN	Density-Based Spatial Clustering of Applications with Noise – algorithme de clustering fondé sur la densité.
EMSI	École Marocaine des Sciences de l'Ingénieur.
GAB	Guichet Automatique Bancaire.
HR	Hazard Ratio – rapport de risque, mesure d'effet d'un modèle de survie de Cox.
MAE	Mean Absolute Error – erreur absolue moyenne, métrique d'évaluation d'un modèle de régression.
PCA	Principal Component Analysis – analyse en composantes principales, méthode de réduction de dimension.
PFE	Projet de Fin d'Études.
RFM	Récence, Fréquence, Montant – méthode de segmentation client.
RMSE	Root Mean Square Error – racine de l'erreur quadratique moyenne, métrique d'évaluation d'un modèle de régression.
ROC	Receiver Operating Characteristic – courbe représentant la performance d'un modèle de classification selon son seuil de décision.
R^2	Coefficient de détermination – part de variance expliquée par un modèle de régression.
UMAP	Uniform Manifold Approximation and Projection – méthode de réduction de dimension non linéaire.
XGBoost	eXtreme Gradient Boosting – algorithme d'apprentissage supervisé par boosting de gradient.

Introduction générale

Dans un contexte de transformation numérique accélérée du secteur bancaire marocain, la carte bancaire s'est imposée comme l'un des vecteurs stratégiques de la relation client. Pourtant, malgré une progression constante du parc de porteurs, un écart significatif subsiste entre le nombre de clients détenteurs d'une carte et ceux qui l'utilisent effectivement pour réaliser des paiements – un manque à gagner direct pour les établissements bancaires, dont une partie des revenus est indexée sur le volume des transactions générées. Attijariwafa Bank, première banque du Maroc, est confrontée à cette même réalité : certains clients effectuent des centaines de transactions par an, tandis que d'autres n'utilisent leur carte que pour des retraits, voire ne l'ont jamais activée pour un paiement.

C'est dans ce cadre que s'inscrit le présent travail, réalisé au sein de l'entité Data BDME d'Attijariwafa Bank : concevoir et mettre en œuvre une stratégie data-driven visant à accroître l'utilisation des cartes bancaires pour les paiements au sein du portefeuille clients de la banque. La problématique centrale peut être formulée ainsi : comment exploiter les données comportementales et transactionnelles des clients pour identifier, segmenter et activer les leviers d'usage de la carte bancaire, et ainsi maximiser le volume de paiements générés ?

Pour répondre à cette question, nous mobilisons des techniques d'apprentissage automatique – segmentation non supervisée, classification prédictive et analyse de survie – selon la méthodologie CRISP-DM, afin de construire un dispositif analytique complet : de la compréhension des profils clients jusqu'à la recommandation d'actions business ciblées.

Le présent rapport s'organise en sept chapitres. Le premier pose le cadre du projet et l'état de l'existant ; les chapitres 2 et 3 couvrent la spécification des besoins et la compréhension des données. Le chapitre 4 construit la base analytique qui sert de socle aux trois derniers chapitres : le chapitre 5 développe la segmentation comportementale de la clientèle, le chapitre 6 étudie la vitesse d'activation et la fidélité qui lui est associée, et le chapitre 7 présente les modèles prédictifs ainsi que les recommandations stratégiques qui en découlent.

Chapitre 1

Présentation du cadre de projet

Introduction

Ce chapitre reprend le sujet déjà présenté en introduction, cette fois en entrant davantage dans les détails techniques. Nous commençons par présenter le cadre académique de ce travail ainsi que l'organisme d'accueil et l'équipe avec laquelle nous avons mené ce travail, avant de dresser un état des lieux de l'existant et de proposer notre solution.

1.1 Cadre académique du projet

Ce projet de fin d'études s'inscrit dans le cadre d'un double diplôme : il vise l'obtention du diplôme national d'ingénieur de l'École Marocaine des Sciences de l'Ingénieur, délivré en partenariat avec Université Côte d'Azur dans le cadre du Master MIAGE – MBDS. Porté au niveau national par le réseau MIAGE (Méthodes Informatiques Appliquées à la Gestion des Entreprises), ce master forme des ingénieurs capables de conjuguer expertise technique et compréhension des enjeux métier – une double compétence directement mobilisée dans ce mémoire, qui articule modélisation statistique et recommandations opérationnelles pour une banque.



FIGURE 1.1 – Établissements partenaires du double diplôme : Master MIAGE – MBDS (Université Côte d'Azur) et École Marocaine des Sciences de l'Ingénieur

Ce mémoire, réalisé lors d'un stage de fin d'études au sein d'Attijariwafa bank, constitue le livrable central de cette double formation.

1.2 Présentation de l'organisme d'accueil

Attijariwafa bank est l'un des principaux groupes bancaires et financiers en Afrique, leader au Maroc et dans la région du Maghreb. Né de la fusion entre la Banque Commerciale du Maroc et Wafabank en 2004, le Groupe s'est progressivement imposé comme un acteur incontournable du secteur financier africain, opérant aujourd'hui dans 26 pays à travers un réseau de plus de 7 000 agences. Il propose une gamme diversifiée de services financiers via ses filiales spécialisées couvrant l'assurance, le crédit à la consommation, la gestion d'actifs et les services de paiement.

Conscient des mutations profondes que traverse le secteur bancaire, Attijariwafa bank s'inscrit résolument dans une dynamique de transformation digitale et de développement durable, avec une ambition affirmée de renforcer son leadership continental à travers son plan stratégique. Dans ce



FIGURE 1.2 – Logo d’Attijariwafa bank, organisme d’accueil de ce projet de fin d’études

contexte, la valorisation de la donnée est devenue un levier stratégique majeur pour améliorer la connaissance client, optimiser les offres et renforcer la compétitivité du Groupe.

Nous avons effectué notre stage au sein de l’entité Data BDME (Big Data & Marketing Engineering) d’Attijariwafa bank. Cette entité occupe une position centrale dans l’écosystème data du Groupe : elle est en charge de la collecte, du traitement et de l’exploitation des données clients afin d’alimenter les décisions marketing et commerciales.

L’entité Data BDME intervient à plusieurs niveaux stratégiques : la modélisation et la segmentation avancée de la base clients, le développement de cas d’usage data au service des directions métiers, la mise en place d’indicateurs de performance et de tableaux de bord analytiques, ainsi que la conception de stratégies fondées sur la donnée (data-driven) pour accompagner la croissance des usages bancaires.

C’est dans ce cadre que s’inscrit notre mission : concevoir une stratégie data-driven pour augmenter l’utilisation des cartes bancaires Attijariwafa Bank, en mobilisant la segmentation comportementale et l’analyse de données au service des enjeux business de l’entité Data BDME.

1.3 Étude de l’existant

1.3.1 Description de l’existant

Actuellement, le suivi de l’usage des cartes bancaires au sein d’Attijariwafa Bank repose principalement sur des reportings statiques et des indicateurs agrégés. Les campagnes d’activation des porteurs sont menées de manière uniforme, sans distinction des profils comportementaux ni anticipation des risques d’inactivité. Bien que les données transactionnelles soient disponibles, elles restent largement sous-exploitées dans le cadre des décisions commerciales.

1.3.2 Critique de l'existant

Cette approche présente plusieurs limites. L'absence de segmentation fine des clients empêche toute personnalisation des actions marketing. Par ailleurs, la détection de l'inactivité intervient de manière réactive, après que le client a déjà réduit ou cessé son usage, ce qui réduit considérablement les chances de réactivation. Enfin, la richesse des données disponibles — comportement transactionnel, usage digital, ratio retraits/paiements — n'est pas exploitée pour guider les décisions opérationnelles.

1.3.3 Solution proposée

Pour répondre à ces lacunes, nous proposons une démarche data-driven structurée autour de trois axes : une segmentation comportementale par apprentissage non supervisé, un modèle de classification pour la prédiction d'inactivité, et un modèle de survie pour l'estimation du risque de désengagement dans le temps. L'ensemble de ces composantes permet de formuler des recommandations stratégiques personnalisées par segment, offrant à la banque un dispositif opérationnel et proactif.

1.4 Choix du modèle de développement

Contrairement aux projets de développement logiciel classiques qui s'appuient sur des modèles tels que le cycle en V ou la méthode Agile, notre projet s'inscrit dans une démarche d'analyse de données. Nous avons donc adopté la méthodologie **CRISP-DM** [Chapman et al., 2000] (*Cross-Industry Standard Process for Data Mining*), reconnue comme le standard de référence dans les projets de data science.

CRISP-DM est un processus itératif organisé en six phases complémentaires :

1. **Compréhension métier** : définir les objectifs du projet du point de vue de la banque et traduire la problématique en tâches analytiques ;
2. **Compréhension des données** : explorer, décrire et évaluer la qualité du dataset mis à disposition ;
3. **Préparation des données** : nettoyer, transformer et enrichir les données en vue de la modélisation ;
4. **Modélisation** : construire et paramétrer les modèles de segmentation, de classification et de survie ;
5. **Évaluation** : valider les résultats obtenus et vérifier leur pertinence métier ;
6. **Déploiement** : formuler les recommandations stratégiques actionnables à destination de la banque.

Ce modèle présente l'avantage d'être flexible et itératif :

il est possible de revenir à une phase précédente à tout moment, ce qui est particulièrement adapté à un projet exploratoire où les données et les besoins métier évoluent au fil de l'analyse.




FIGURE 1.3 – Les six phases du modèle CRISP-DM

1.5 Planning prévisionnel

Le déroulement du projet a été organisé selon les six phases de la méthodologie CRISP-DM présentée ci-dessus, du cadrage initial jusqu’au déploiement des recommandations. Le planning ci-dessous détaille la répartition de ces phases sur la durée du stage.




FIGURE 1.4 – Planning prévisionnel

Conclusion

Ce premier chapitre a permis de poser le cadre de ce projet : la présentation de l'organisme d'accueil et de l'entité Data BDME, l'étude de l'existant qui justifie une approche data-driven, ainsi que le choix de la méthodologie CRISP-DM qui structure la suite de ce mémoire. Le chapitre suivant précise les besoins fonctionnels et non fonctionnels du système analytique à construire.

Chapitre 2

Spécification des besoins

Introduction

Ce chapitre présente les besoins fonctionnels et non fonctionnels du système proposé dans le cadre du projet. L'objectif est de clarifier les fonctionnalités attendues, les contraintes de qualité, ainsi que les interactions principales entre les acteurs du système et la plateforme analytique.

Dans ce projet, le système vise à exploiter les données clients, cartes, transactions, commerçants et canaux digitaux afin de construire une base analytique exploitable pour la segmentation, le scoring et la modélisation prédictive. La spécification des besoins constitue ainsi une étape fondamentale pour cadrer le périmètre du système et orienter les choix de conception.

2.1 Besoins fonctionnels

Les besoins fonctionnels décrivent les services que le système doit fournir aux utilisateurs et aux processus métiers. Dans le cadre de ce projet, ils sont organisés selon les principaux domaines fonctionnels du système.

2.1.1 Gestion et préparation des données

- Importer les données issues des différentes sources ;
- Vérifier la présence et la cohérence des champs obligatoires ;
- Nettoyer les données brutes en supprimant les doublons et en traitant les valeurs manquantes ;
- Standardiser les formats de dates, montants et identifiants ;
- Construire une table agrégée par client à partir de l'historique transactionnel.

2.1.2 Analyse descriptive et segmentation

- Calculer les indicateurs descriptifs de base sur les clients et les transactions ;
- Mesurer la fréquence, la récence et le volume d'utilisation de la carte ;
- Identifier les comportements d'usage dominants ;
- Segmenter les clients selon leur niveau d'usage de la carte ;
- Visualiser les distributions et les tendances comportementales.

2.1.3 Préparation des variables analytiques

- Construire des variables RFM adaptées au contexte bancaire ;
- Générer des variables comportementales liées à l'usage carte ;
- Construire des variables temporelles pour les modèles de prédiction ;
- Préparer des variables digitales, financières et commerciales ;
- Assurer la disponibilité des variables avant l'événement à prédire.

2.1.4 Modélisation prédictive

- Estimer la propension à l'activation des clients ;
- Prédire l'activation d'un nouveau client à J+30 ;
- Estimer le délai avant activation ou désengagement ;
- Identifier le frein principal à l'usage de la carte ;
- Scorer les commerçants ou zones géographiques à fort potentiel.

2.1.5 Restitution et pilotage

- Produire des scores interprétables pour les équipes métier ;
- Générer des tableaux de bord de suivi ;
- Proposer des recommandations actionnables par segment ;
- Suivre les indicateurs de performance métier et data science ;
- Préparer les livrables nécessaires à l'analyse et à la soutenance.

2.2 Besoins non fonctionnels

Les besoins non fonctionnels décrivent les contraintes de qualité que le système doit respecter. Ils concernent notamment les performances, la sécurité, la disponibilité, la maintenabilité et l'évolutivité du système.

2.2.1 Performance

Le système doit pouvoir traiter un volume important de données transactionnelles dans un délai raisonnable. Les opérations de préparation, d'agrégation et de calcul des indicateurs doivent rester efficaces afin de permettre une exploitation fluide des données.

- Temps de traitement acceptable pour les jeux de données de taille moyenne ;
- Calcul rapide des agrégations par client et par période ;
- Exécution des modèles de scoring dans un temps compatible avec les besoins métiers.

2.2.2 Sécurité

Le système doit garantir la confidentialité et l'intégrité des données bancaires et clients. L'accès aux données sensibles doit être strictement contrôlé.

- Authentification des utilisateurs autorisés ;
- Autorisation par profil ou niveau d'accès ;
- Chiffrement ou anonymisation des données sensibles lorsque nécessaire ;
- Respect des règles de confidentialité et de gouvernance des données.

2.2.3 Disponibilité

Le système doit être disponible de manière fiable pendant toute la durée de l'analyse et du traitement. Les données préparées doivent pouvoir être réutilisées sans perte ni altération.

- Disponibilité suffisante pour les travaux d'analyse et de modélisation ;
- Sauvegarde régulière des fichiers intermédiaires et finaux ;
- Réduction des risques de perte de données lors des traitements.

2.2.4 Maintenabilité

Le code et les traitements doivent être simples à comprendre, à corriger et à faire évoluer. La structure du projet doit permettre d'ajouter facilement de nouvelles variables ou de nouveaux modèles.

- Code modulaire et bien structuré ;
- Documentation claire des traitements ;

- Nommage cohérent des fichiers, variables et tables ;
- Facilité d’adaptation à d’autres jeux de données ou à d’autres segments.

2.2.5 Ergonomie et lisibilité

Les résultats du système doivent être présentés de manière claire et exploitable. Les tableaux de bord, tableaux de sortie et fichiers générés doivent être faciles à interpréter.

- Présentation lisible des résultats ;
- Noms explicites pour les variables et les colonnes ;
- Visualisations compréhensibles pour les utilisateurs métier.

2.3 Modélisation des cas d’utilisation

La modélisation des cas d’utilisation permet de représenter les interactions entre les acteurs et le système. Contrairement à une application interactive classique, le « système » modélisé ici est le dispositif analytique dans son ensemble – de la préparation des données jusqu’à la restitution des recommandations – et non une interface graphique. Deux acteurs interagissent avec ce dispositif : le **Data Analyst**, qui construit et exécute le pipeline, et l’équipe **Marketing** de l’entité Data BDME, qui exploite les résultats produits.

2.3.1 Vue d’ensemble

Le diagramme de cas d’utilisation ci-dessous reprend directement les catégories de besoins fonctionnels définies en section 2.1 : le Data Analyst prend en charge la préparation des données, la segmentation, l’entraînement des modèles prédictifs et le scoring, tandis que l’équipe Marketing consulte les résultats produits pour prioriser ses actions commerciales.

2.3.2 Zoom sur l’entraînement des modèles prédictifs

Le cas d’utilisation « Entraîner les modèles prédictifs » regroupe en réalité cinq modèles distincts, développés et présentés séparément au chapitre 7 : c’est une relation d’inclusion («include») au sens UML, puisque l’entraînement complet du dispositif implique systématiquement ces cinq étapes.

Conclusion

Ce chapitre a précisé les besoins fonctionnels et non fonctionnels attendus du système analytique, ainsi que les principales interactions entre acteurs et plateforme. Ce cadrage sert de référence pour les choix de conception effectués dans la suite du projet. Le chapitre suivant est consacré à la compréhension et à la préparation des données mobilisées pour répondre à ces besoins.




FIGURE 2.1 – Diagramme de cas d'utilisation – vue d'ensemble du dispositif analytique




FIGURE 2.2 – Diagramme de cas d'utilisation – détail du cas « Entraîner les modèles prédictifs »

Chapitre 3

Compréhension et préparation des données

Introduction

Dans ce chapitre, nous posons les bases du projet en commençant par introduire les tables clients du jeu de données, fourni par l'encadrant entreprise **Wassim Tahir**. Grâce aux extractions qu'il a réalisées, nous avons pu établir, avec son aide, un dictionnaire de données dans lequel chaque variable des tables client est expliquée : cette étape de gouvernance des données est indispensable pour assurer la traçabilité, la clarté des variables et la rigueur de l'analyse. Au-delà de la simple présentation des tables, nous détaillons également la manière dont nous avons vérifié la cohérence des données, leur granularité, leur structure et leur exploitabilité : ce travail conditionne directement l'axe suivant, consacré à la construction de la base analytique et aux variables dérivées.

3.1 Présentation des tables

Nous présentons ici les tables disponibles, en soulignant leur importance pour la stratégie data-driven que nous cherchons à construire.

Deux extractions ont été réalisées. La première, que nous avons nommée *table_paiement*, regroupe les informations relatives au client : elle contient 50 000 lignes et 33 colonnes, que nous avons choisi de répartir comme suit :

Afin de faciliter la lecture du jeu de données, les variables ont été regroupées en dix catégories homogènes selon leur nature métier et leur rôle analytique. Cette structuration permet de distinguer les variables d'identification, de profil client, de comportement bancaire, d'activité transactionnelle et d'usage digital. Elle offre ainsi une lecture plus claire des données disponibles et prépare leur exploitation dans les étapes d'analyse suivantes.

TABLE 3.1: Identification du client

Variable	Description
ID	Identifiant unique du client.

La deuxième catégorie regroupe les variables d'ancienneté et de dates, qui situent chaque client dans le temps par rapport au début de sa relation bancaire et à ses premières opérations.

TABLE 3.2: Ancienneté et dates de relation

Variable	Description
anciennete_jours	Ancienneté de la relation client en jours.
dt_deb_rela	Date de début de la relation bancaire.
dat_prem_paiement	Date du premier paiement observé.
dat_prem_retrait	Date du premier retrait observé.

Les variables suivantes décrivent le profil socio-démographique du client.

TABLE 3.3: Profil socio-démographique

Variable	Description
Age	Âge du client.
Genre	Genre du client.
Profession	Profession du client.
ville_principale	Ville principale du client.

Le positionnement bancaire du client, c'est-à-dire son rattachement à un marché et un niveau de service, est précisé par les variables suivantes.

TABLE 3.4: Positionnement bancaire

Variable	Description
Marché	Segment ou marché bancaire du client.
Niveau de service	Niveau de service ou d'offre associé au client.
segment_metier	Segment métier attribué au client.

Les variables de paiement, au cœur de ce projet, distinguent les flux locaux des flux internationaux, en nombre comme en montant.

TABLE 3.5: Paiements locaux et internationaux

Variable	Description
Nombre_local	Nombre de paiements locaux.
Volume_local	Montant total des paiements locaux.
Nombre_international	Nombre de paiements internationaux.
Volume_international	Montant total des paiements internationaux.

Les retraits en guichet automatique bancaire, qui concurrencent le paiement carte dans l'usage quotidien du client, sont décrits par les deux variables suivantes.

TABLE 3.6: Retraits GAB

Variable	Description
nbr_retraits_gab	Nombre de retraits GAB effectués par le client.
mnt_retraits_gab	Montant total des retraits GAB effectués par le client.

L'usage du canal digital est capté par les variables d'activité sur l'application mobile.

TABLE 3.7: Activité sur l'application

Variable	Description
nbr_connexion_app	Nombre de connexions à l'application.
has_app_connexion	Indicateur indiquant si le client s'est déjà connecté à l'application.

Les mouvements globaux de crédits et de débits du compte, indépendamment du canal utilisé, sont résumés par les variables suivantes.

TABLE 3.8: Crédits et débits

Variable	Description
nbr_credit	Nombre de crédits enregistrés.
nbr_debit	Nombre de débits enregistrés.
montant_total_credits	Montant total des crédits.
montant_total_debits	Montant total des débits.

Ces variables consolident enfin l'activité de paiement du client sous forme de totaux et de parts relatives.

TABLE 3.9: Paiements totaux

Variable	Description
nb_paiements_total	Nombre total de paiements.
mnt_paiements_total	Montant total des paiements.
part_paiement	Part des paiements dans l'activité globale.

Enfin, la répartition de l'activité entre paiement et retrait, ainsi que le principal regroupement de dépenses du client, est précisée par les variables suivantes.

TABLE 3.10: Répartition de l'activité

Variable	Description
part_retrait	Part des retraits dans l'activité globale.
ens_pv_top_2025	Indicateur de groupe ou ensemble de dépenses principal.
premiere_ens_pv	Premier ensemble de dépenses ou premier regroupement observé.

Malgré la richesse de ses variables, cette première table ne suffit pas à elle seule pour mener les analyses souhaitées : elle ne comprend aucun client jamais actif, c'est-à-dire n'ayant réalisé aucun paiement local ou international.

Nous avons donc procédé à une seconde extraction, depuis une autre source, que nous avons intitulée *clients_jamais_actifs*. Cette table contient des variables tout aussi riches que celles de la première, réparties sur 60 000 lignes et 19 colonnes.

TABLE 3.11: Identification du client

Variable	Description
ID	Identifiant unique du client.

Les variables d'activité CMC décrivent les virements réalisés par le client, en nombre comme en montant.

TABLE 3.12: Activité CMC

Variable	Description
M_VIREMENT_cmc	Montant total des virements réalisés dans le cadre de l'activité CMC.
F_VIREMENT_cmc	Nombre de virements réalisés dans le cadre de l'activité CMC.
V_CMC	Indicateur synthétique de volume lié à l'activité CMC.
F_CMC	Indicateur synthétique de fréquence lié à l'activité CMC.

Les variables d'activité CMD complètent cette lecture avec les retraits et virements associés à ce canal.

TABLE 3.13: Activité CMD

Variable	Description
M_RETRAITS_cmd	Montant total des retraits associés à l'activité CMD.
M_VIREMENT_cmd	Montant total des virements associés à l'activité CMD.
f_RETRAITS_cmd	Nombre de retraits associés à l'activité CMD.
f_VIREMENT_cmd	Nombre de virements associés à l'activité CMD.
V_CMD	Indicateur synthétique de volume lié à l'activité CMD.
F_CMD	Indicateur synthétique de fréquence lié à l'activité CMD.

Le profil socio-démographique du client est décrit par les variables suivantes, portant ici le suffixe ORDO propre à cette seconde source de données.

TABLE 3.14: Profil socio-démographique

Variable	Description
profession_ORDO	Profession du client telle qu'enregistrée dans le référentiel ORDO.
age_client_ORDO	Âge du client.
genre_ORDO	Genre du client.
Ville	Ville de résidence principale du client.

La relation bancaire du client est ensuite caractérisée par les variables suivantes.

TABLE 3.15: Relation bancaire

Variable	Description
Date Début Relation	Date de début de la relation bancaire avec le client.
niveau de service ORDO	Niveau de service ou d'offre associé au client.
Marché_ORDO	Segment ou marché bancaire du client.

Enfin, l'usage digital du client est mesuré par la variable suivante.

TABLE 3.16: Usage digital

Variable	Description
nbr_connexion_app	Nombre de connexions à l'application bancaire.

3.2 Contrôles de cohérence et qualité

Avant toute exploitation analytique, un ensemble de contrôles de cohérence et de qualité a été appliqué afin de garantir la fiabilité du jeu de données. Nous avons ainsi mené une étape d'analyse des tables extraites, à l'aide de scripts Python mobilisant des bibliothèques telles que pandas [McKinney, 2010], numpy et pathlib – retenues parce qu'elles répondaient bien à nos besoins. Notre objectif était double : vérifier les tables et unifier leur format, mais aussi contrôler la qualité des données afin de pouvoir nous y appuyer pendant l'étape de segmentation et les rendre pleinement exploitables par les modèles prédictifs.

3.2.1 Nettoyage de la première table client

Le fichier initial de la première table contenait 50 000 lignes et 23 colonnes. Nous avons d'abord vérifié l'unicité de l'identifiant client ID. Aucun doublon n'a été détecté, ni avant ni après le contrôle, ce qui confirme que chaque ligne correspond à un client unique.

Nous avons ensuite converti les variables de dates dans un format temporel homogène afin de pouvoir les exploiter dans les calculs d'ancienneté et dans les analyses chronologiques. Les champs correspondant à la date de début de relation, à la date du premier paiement et à la date du premier retrait ont tous été transformés en format `datetime64[ns]`. Le nombre de valeurs manquantes observé sur chacune de ces trois variables est resté stable, avec 633 valeurs manquantes avant et après conversion, ce qui montre que cette transformation n'a pas introduit de perte d'information supplémentaire.

Nous avons également converti les variables numériques dans des formats adaptés à l'analyse. Les variables de nombre et de montant, telles que les volumes de paiements, les retraits GAB, les crédits et les débits, ont été contrôlées afin de détecter les valeurs non interprétables. Une attention particulière a été accordée à la variable Age. Après conversion, le nombre de valeurs manquantes est passé de 633 à 640, ce qui s'explique par l'exclusion des âges incohérents, inférieurs à 0 ou supérieurs à 100.

Les valeurs manquantes ne sont pas réparties de manière uniforme entre les variables. Certaines colonnes comportementales présentent un volume plus élevé d'informations absentes, comme le nombre de connexions à l'application, qui contient 5 018 valeurs manquantes. D'autres variables, telles que les retraits GAB, les crédits, les débits, les montants totaux de crédits et de débits, présentent également des valeurs manquantes, mais dans des proportions plus limitées. Cette observation nous a permis d'identifier les champs les plus sensibles avant la phase de construction de la base analytique.

Les variables textuelles ont, quant à elles, fait l'objet d'un nettoyage syntaxique afin d'harmoniser les libellés et d'éliminer les espaces inutiles. Les champs relatifs à la ville principale, au niveau de service, au genre, au marché, à la profession ainsi qu'aux variables de segmentation ont été uniformisés. Ce travail nous a permis d'améliorer la cohérence des catégories et d'éviter la multiplication

artificielle de modalités équivalentes mais écrites différemment.

En définitive, la présentation des tables, leur regroupement par catégories de variables ainsi que les contrôles de cohérence réalisés constituent une étape préalable indispensable à toute analyse approfondie. Ce travail de structuration nous a permis de clarifier la nature des données disponibles, d'en vérifier la fiabilité et d'en préciser les usages possibles dans le cadre du projet.

3.2.2 Nettoyage de la deuxième table client

Nous avons nettoyé ce fichier selon la même démarche que pour la première table, décrite ci-dessus.

Nous avons commencé par vérifier la structure générale de cette table afin de nous assurer de la cohérence des données disponibles. La table contenait 60 000 lignes et 19 colonnes, avec un identifiant client unique, sans doublons. Ensuite, nous avons analysé chaque colonne afin d'identifier sa nature, de repérer les valeurs manquantes et de détecter les éventuelles incohérences de format.

Nous avons ensuite converti les variables de dates dans un format exploitable pour l'analyse, ce qui nous a permis de conserver leur dimension temporelle. Une seule date a été conservée comme valeur manquante, car elle était initialement codée par un tiret et ne pouvait pas être interprétée correctement. Nous avons procédé de la même manière pour la variable d'âge : les valeurs nulles codées par un tiret ainsi que les âges aberrants supérieurs à 100 ans ont été remplacés afin de garantir la cohérence des traitements statistiques.

Par ailleurs, nous avons nettoyé les variables numériques relatives aux montants et aux fréquences afin de les rendre directement exploitables dans les analyses futures. Les variables textuelles ont également été harmonisées pour supprimer les espaces inutiles et recoder certaines modalités non renseignées. Ce travail nous a permis de constater que plusieurs valeurs présentées comme renseignées correspondaient en réalité à des non-réponses, notamment dans la variable ville, où le tiret était utilisé comme code de valeur manquante.

Enfin, nous avons créé deux variables dérivées, à savoir l'ancienneté client en jours et un indicateur de connexion à l'application. À l'issue de ce nettoyage, la base est devenue plus cohérente, plus lisible et mieux adaptée à la construction de la base analytique et aux analyses qui seront réalisées par la suite.

3.3 Bilan du nettoyage des deux tables

Au terme du nettoyage des deux tables, nous disposons désormais d'un jeu de données plus cohérent, mieux structuré et directement exploitable pour la suite du projet. La première table contenait initialement 50 000 lignes et 23 colonnes, puis 25 colonnes après ajout des variables dérivées. La deuxième table contenait 60 000 lignes et 19 colonnes, puis 21 colonnes après enrichissement. Dans les deux cas, nous avons vérifié l'unicité des identifiants clients et confirmé l'absence de doublons.

Sur le plan temporel, les variables de dates ont été harmonisées dans un format exploitable, ce

qui nous a permis de calculer l'ancienneté client dans les deux tables. Les contrôles effectués ont également mis en évidence un nombre très limité de valeurs non interprétables, notamment une seule date manquante dans la deuxième table, que nous avons conservée comme valeur nulle car son impact reste négligeable à l'échelle de la base.

Le nettoyage a également porté sur les variables numériques. Dans la première table, nous avons corrigé plusieurs incohérences, notamment sur la variable Age, ainsi que sur certaines variables comportementales présentant des valeurs manquantes. Dans la deuxième table, nous avons transformé la variable d'âge en variable numérique et remplacé les valeurs nulles codées par des tirets ainsi que les âges aberrants supérieurs à 100 ans. Ce traitement nous a permis de fiabiliser les variables les plus sensibles pour l'analyse descriptive et comparative.

Enfin, les variables textuelles ont été harmonisées dans les deux tables afin de supprimer les espaces inutiles, recoder certaines modalités de non-réponse et clarifier les catégories. Le nettoyage a également montré que certaines valeurs initialement considérées comme renseignées correspondaient en réalité à des codes de valeurs manquantes, comme le tiret utilisé dans plusieurs champs. Cette étape a donc permis non seulement de corriger la structure des données, mais aussi de mieux interpréter le sens réel des valeurs présentes.

Conclusion

En résumé, le nettoyage des deux tables a renforcé la qualité, la lisibilité et la cohérence de la base de travail. Il a préparé le terrain pour la construction de la base analytique, qui constituera l'étape suivante du projet.

Le chapitre suivant sera consacré à l'axe 2, à savoir la construction de la base analytique. Cette étape consistera à agréger les informations pertinentes au bon niveau de granularité, tout en respectant les contraintes méthodologiques liées aux fuites temporelles, à la séparation entre période d'observation et période de prédiction, ainsi qu'à la traçabilité des transformations. Elle permettra ainsi de disposer d'une base consolidée et exploitable pour les analyses exploratoires et les travaux de modélisation à venir.

Chapitre 4

Construction de la base analytique

Introduction

Une fois les deux tables nettoyées et contrôlées, nous avons pu passer à l'étape de construction de la base analytique. Cette phase consiste à transformer les données disponibles en une structure consolidée, organisée au bon niveau de granularité et directement exploitable pour les analyses du projet.

L'objectif n'est plus seulement de disposer de données propres, mais de construire une base cohérente, documentée et adaptée aux besoins de modélisation. Pour cela, nous devons sélectionner les variables pertinentes, créer les indicateurs dérivés nécessaires et vérifier la cohérence entre les montants, les fréquences et les statuts afin de garantir la fiabilité de l'ensemble.

4.1 Choix de la granularité des tables

Les données que nous exploitons dans le cadre de ce projet sont organisées en deux tables distinctes mais complémentaires, toutes deux orientées client. Dans chacune de ces tables, chaque ligne représente un client unique identifié par un identifiant spécifique. Cette granularité nous permet de regrouper, pour chaque client, l'ensemble des informations nécessaires à l'analyse de son comportement bancaire, notamment ses caractéristiques sociodémographiques, son ancienneté dans la banque, son niveau d'activité, son utilisation des différents canaux bancaires ainsi que ses habitudes de paiement, qu'il privilégie les transactions en espèces ou les paiements par carte.

Ce choix de granularité est cohérent avec l'objectif du projet, qui consiste à construire une base analytique exploitable pour des modèles de propension, d'activation et de priorisation commerciale. Il permet de comparer les clients entre eux sur une base homogène, sans être contraint par une logique transactionnelle ou temporelle détaillée que les données disponibles ne permettent pas d'exploiter pleinement.

Ainsi, la base analytique finale est construite au niveau client, en agrégeant les variables pertinentes issues des différentes tables disponibles. Cette approche facilite la fusion des données, la création d'indicateurs dérivés et la préparation des étapes ultérieures d'analyse exploratoire et de modélisation.

4.2 Définition des variables cible

Nous avons définis les variables cibles du projet en cohérence avec les objectifs analytiques retenus. Plutôt qu'une cible unique, l'étude s'organise autour de plusieurs problématiques complémentaires : la propension à l'activation, l'activation à J+30, le délai avant activation ou désengagement, la classification des freins à l'usage et le scoring des commerçants à prioriser. Cette structuration permet de couvrir à la fois la dimension client, la dimension temporelle et la dimension commerciale du projet.

Afin de rendre la lecture du projet plus claire, la section consacrée aux variables cibles est structurée en plusieurs sous-parties. Chaque sous-partie correspond à un modèle analytique précis et présente la variable cible associée, sa logique de construction ainsi que son intérêt métier. Cette organisation permet de passer progressivement d'une cible principale, le modèle d'activation, vers les cibles secondaires liées à la propension à l'usage, à l'identification des freins et à la priorisation des commerçants.

4.2.1 Modèle d'activation

4.2.1.1 Modèle de propension à la montée en usage

Le premier modèle retenu dans ce travail est le modèle de propension à la montée en usage. Ce modèle a pour objectif d'identifier, parmi les clients déjà présents dans la base, ceux qui présentent un fort potentiel d'augmentation de leur niveau d'usage. Autrement dit, il ne s'agit pas ici de prédire une première activation, mais plutôt d'évaluer la probabilité qu'un client peu actif ou moyennement actif devienne un client plus engagé dans l'utilisation des services bancaires étudiés.

Nous construisons ce modèle en premier lieu à partir de la première table, qui regroupe les clients actifs, moyennement actifs et peu actifs, et qui contient donc les informations les plus adaptées pour caractériser les différences de comportement entre ces profils.

La cible du modèle repose sur une logique de segmentation comportementale. À partir des règles métier définies dans le cadre du projet, chaque client peut être rattaché à une classe d'activité, par exemple : client peu actif, client moyennement actif ou client actif. Cette variable cible peut également être simplifiée en une formulation binaire, où la classe 1 représente les clients ayant un fort potentiel d'activation ou de montée en usage, et la classe 0 les autres clients. Le choix entre une cible binaire ou multiclassées dépend de la finesse d'analyse souhaitée et de la lisibilité recherchée dans les résultats finaux.

Pour construire cette cible et entraîner le modèle, nous mobilisons plusieurs variables issues de la première table.

Les variables de profil, telles que l'âge, le genre, le marché, le niveau de service, la profession et la ville principale, permettent de caractériser le client sur un plan sociodémographique et bancaire.

Les variables liées à l'ancienneté et à la relation bancaire, comme la date de début de relation et l'ancienneté en jours, apportent une mesure de maturité de la relation client.

Les variables d'activité, telles que le nombre et le volume des transactions locales et internationales, le nombre et le montant des retraits GAB, le nombre de connexions à l'application bancaire,

les indicateurs d’usage digital, ainsi que les montants totaux crédités et débités, permettent quant à elles de décrire le niveau réel d’engagement du client.

Enfin, **les variables de synthèse**, comme le nombre total de paiements, le montant total des paiements, le nombre total de retraits, le montant total retiré, la part des paiements et la part des retraits, offrent une lecture consolidée du comportement bancaire.

En complément de ces variables brutes, nous construisons également des variables dérivées afin d’enrichir la qualité de la modélisation, notamment des indicateurs tels que :

- la part des paiements dans l’ensemble des opérations ;
- la part des retraits dans l’activité totale ;
- des ratios entre les montants et les fréquences d’utilisation.

De la même manière, nous construisons des variables de regroupement pour synthétiser le niveau d’activité du client, par exemple :

- un score global d’usage ;
- une classe d’activité ;
- un indicateur de comportement dominant.

4.2.1.2 Modèle de propension à la première activation

La deuxième table, quant à elle, regroupe les clients jamais actifs. Elle permet d’étudier un autre segment de la population, à savoir les clients qui n’ont encore réalisé aucun paiement carte, mais qui présentent tout de même certains signaux d’activité bancaire ou digitale. Cette table est donc particulièrement pertinente pour identifier les profils susceptibles de réaliser une première activation, en s’appuyant sur des indicateurs tels que l’ancienneté de la relation, les opérations bancaires observées, l’usage de l’application mobile et les caractéristiques sociodémographiques du client.

Pour construire cette cible et entraîner le modèle, nous mobilisons plusieurs variables issues de la deuxième table.

Les variables de profil, telles que la profession, l’âge client, le niveau de service, le marché, la ville et le genre, permettent de caractériser le client sur un plan sociodémographique et bancaire. Ces informations offrent un premier niveau de lecture du profil et facilitent l’identification des clients présentant des caractéristiques proches de ceux qui s’activent plus facilement.

Les variables liées à la relation bancaire, comme la date de début de relation et l’ancienneté en jours, apportent une mesure de la maturité de la relation client. Elles permettent d’apprécier depuis combien de temps le client est rattaché à l’établissement et de distinguer les profils récents des profils installés, ce qui constitue un élément important dans l’analyse du potentiel d’activation.

Les variables d’activité bancaire, telles que les montants de virements, les fréquences de virements, les montants de retraits, ainsi que les indicateurs V_CMC , F_CMC , V_CMD et F_CMD , permettent de décrire l’intensité des comportements bancaires observés en dehors du paiement carte. Ces variables traduisent le niveau d’interaction du client avec les services bancaires et constituent des signaux utiles pour repérer un potentiel futur d’activation.

Les variables d’usage digital, comme le nombre de connexions à l’application bancaire et l’indicateur *has_app_connexion*, offrent une lecture complémentaire du comportement du client. Elles

permettent d'évaluer son niveau d'engagement digital, lequel peut constituer un signal favorable à l'adoption future du service étudié.

Enfin, **les variables de synthèse** issues de la table, regroupant l'ensemble des informations disponibles, permettent de consolider la lecture comportementale du client et de faciliter la comparaison entre profils.

En complément de ces variables brutes, nous construisons également des variables dérivées afin d'enrichir la qualité de la modélisation, notamment des indicateurs tels que :

- l'intensité des virements ;
- l'intensité des retraits ;
- la présence ou non d'un usage digital ;
- un ratio entre les connexions à l'application et l'ancienneté ;
- un score global de potentiel d'activation.

De la même manière, nous construisons des variables de regroupement pour synthétiser le profil du client, par exemple :

- une classe de potentiel d'activation ;
- un indicateur de comportement bancaire dominant ;
- un score de proximité avec l'usage cible.

Ces variables permettent de mieux faire ressortir les écarts entre les profils de clients et d'identifier plus facilement ceux qui disposent d'un potentiel de montée en activité.

Ainsi, le modèle de propension à l'activation repose sur une base client enrichie par des variables de profil, d'usage et de synthèse, ainsi que par des variables dérivées construites à partir des données disponibles. Cette approche permet de produire un score exploitable pour cibler les clients à fort potentiel et orienter les actions commerciales ou relationnelles de manière plus pertinente.

4.2.2 Modèle d'activation J30

Un modèle prédictif d'activation à J+30 supposerait de disposer, pour chaque client, de variables mesurées uniquement avant son activation, ainsi que d'un découpage temporel strict entre période d'observation et période de prédiction. Or, les données mobilisées dans ce projet se présentent sous forme de totaux cumulés à la date d'extraction (nombre et volume de paiements, de retraits, de connexions à l'application), sans historique daté transaction par transaction. Il n'est donc pas possible de reconstituer, pour un client donné, l'état exact de son comportement au moment précis de son activation, ni de garantir l'absence de fuite d'information entre le passé et le futur : un véritable modèle prédictif à J+30 n'est donc pas réalisable en l'état sur ce jeu de données.

Nous préparons à la place les variables nécessaires à une étude rétrospective et comparative, moins ambitieuse mais exploitable avec les données disponibles : comparer, parmi les clients déjà activés de la table 1, le niveau d'engagement ultérieur des clients selon la rapidité de leur première activation. Cette préparation repose sur trois étapes.

La première consiste à construire un **délai d'activation**, défini comme l'écart en jours entre la date de début de relation bancaire (*dt_deb_rela*) et la date du premier paiement observé (*dat_prem_paiement*). Ce calcul impose d'écarter les lignes non exploitables : les dates manquantes, ainsi que les délais né-

gatifs, c'est-à-dire les cas où un paiement est enregistré avant le début officiel de la relation, une anomalie incompatible avec la logique métier qui devra être vérifiée auprès de la source des données plutôt que corrigée arbitrairement.

La deuxième étape consiste à regrouper les clients en classes de vitesse d'activation – activation rapide, intermédiaire et tardive – à partir de seuils sur ce délai, afin de disposer de populations comparables entre elles.

La troisième étape consiste à préparer une mesure de fidélité qui ne soit pas biaisée par le temps d'exposition : comparer directement les totaux cumulés de paiement favoriserait mécaniquement les clients activés tôt, qui ont eu plus de temps pour accumuler des opérations. Un rythme d'usage mensuel est donc construit en rapportant l'activité de paiement à la durée écoulée depuis l'activation, et non depuis le début de la relation. Cette mesure continue est complétée par un rapprochement avec le segment d'usage actuel du client, issu de la segmentation renforcée présentée au chapitre suivant.

Les résultats obtenus à partir de ces variables préparées sont présentés et interprétés au chapitre 6.

4.2.3 Modèle de classification actif / jamais actif

Ce modèle correspond à la classification XGBoost annoncée en introduction pour prédire l'inactivité des porteurs de cartes. Les deux tables étudiées constituant déjà, par construction, les deux classes recherchées – les clients de la table 1 ayant réalisé au moins un paiement carte, ceux de la table 2 n'en ayant jamais réalisé – la préparation de la base consiste à rapprocher ces deux populations sur un socle de variables communes, plutôt qu'à construire une cible supplémentaire.

4.2.3.1 Harmonisation des variables communes aux deux tables

Les deux tables ne partagent pas exactement les mêmes colonnes, ni les mêmes noms de variables. Un travail d'harmonisation a donc été nécessaire pour ramener les informations comparables sous une nomenclature commune : âge, genre, profession, marché, niveau de service, ville, ancienneté en jours et usage digital (nombre de connexions à l'application). Les modalités textuelles (genre, profession, marché, niveau de service, ville) ont également été uniformisées en majuscules et débarrassées des espaces superflus, afin d'éviter une multiplication artificielle de catégories équivalentes entre les deux sources.

4.2.3.2 Écart des variables porteuses d'un risque de fuite de cible

Certaines variables ne peuvent pas être retenues, car elles définissent la cible par construction, la reproduisent indirectement, ou introduisent un biais de population entre les deux sources.

Les variables de paiement carte de la table 1 (nombre et volume de paiements locaux et internationaux) sont exclues sans ambiguïté, puisqu'un client de la table 1 est par définition celui qui en possède. Les variables de crédits et débits bancaires globaux (*nbr_credit*, *nbr_debit*, *montant_total_credits*, *montant_total_debits*) ont également été écartées : une vérification empirique montre une corrélation de 0,69 entre le nombre de débits et le nombre total de paiements carte du client, ce qui indique que

les paiements carte sont très probablement comptabilisées dans ces totaux.

Un premier essai de modélisation, incluant le marché et le nombre/montant de retraits en guichet automatique, a fait apparaître un problème plus structurel : la table 2 ne contient, sans aucune exception, que des clients du marché « PARTICULIER », alors que la table 1 couvre également les entreprises, professionnels et marocains résidant à l'étranger. La variable marché devenait de fait un identifiant quasi parfait de la table d'origine plutôt qu'un signal comportemental, et a donc été retirée des variables explicatives – la base a en outre été restreinte au marché « PARTICULIER » dans les deux tables, afin de comparer des populations réellement comparables. De la même manière, le nombre de retraits en guichet automatique de la table 1 (*nbr_retrait_gab*, dont les valeurs extrêmes ont déjà été signalées comme anomalie de données) s'est révélé sur une échelle sans rapport avec la fréquence de retrait de la table 2, malgré la proximité de leurs intitulés : ces deux variables ne mesurent manifestement pas la même chose et ont donc été écartées plutôt que rapprochées à tort.

Seules les variables dont l'indépendance vis-à-vis du paiement carte et la comparabilité entre les deux tables sont raisonnablement établies – profil socio-démographique, ancienneté et usage digital – ont finalement été conservées.

4.2.3.3 Base obtenue

Après restriction au marché « PARTICULIER », le rapprochement des deux tables produit une base de 94 111 clients, réunissant 34 111 clients de la table 1 (classe « actif », 36,2 % de la base) et 60 000 clients de la table 2 (classe « jamais actif », 63,8 % de la base). Les 15 889 clients de la table 1 hors marché « PARTICULIER » sont exclus de ce modèle, faute d'équivalent dans la table 2. Les valeurs manquantes propres à chaque variable ont été conservées telles quelles à ce stade et seront traitées lors de la phase de modélisation proprement dite, au chapitre consacré à la modélisation prédictive.

4.2.4 Délai avant activation ou désengagement

Le volet « délai avant activation » de cette cible est déjà couvert par l'étude préparée plus haut dans ce chapitre et présentée au chapitre 6 : le délai entre le début de la relation bancaire et le premier paiement carte y est calculé et exploité pour la table 1.

Le volet « désengagement » a d'abord été écarté pour la même raison qu'un modèle prédictif à J+30 : les variables disponibles pour la table 1 (nombre et volume de paiements, de retraits, de connexions) sont des totaux cumulés à la date d'extraction, qui ne permettent pas de savoir si un client encore jugé « actif » au global n'a en réalité plus effectué de paiement depuis plusieurs mois. Un historique transactionnel daté est ensuite devenu disponible en cours de projet : l'encadrant entreprise a transmis une extraction complémentaire fournissant, pour chaque client de la table 1, la date de son dernier paiement (*dat_dern_paiement*), à la date de référence du 31 décembre 2025.

Cette nouvelle variable a d'abord fait l'objet d'un contrôle de cohérence : vérification de la jointure avec la table 1 par identifiant client (et non par position de ligne), absence de client sans correspondance dans un sens ou dans l'autre, et recoupement des valeurs manquantes (633, exactement les

mêmes clients déjà signalés lors du nettoyage du chapitre 3).

Le désengagement est défini par un **seuil d'inactivité** : un client est considéré désengagé si son dernier paiement remonte à plus de 120 jours à la date de référence, et censuré sinon. Ce seuil a été choisi empiriquement plutôt qu'arbitrairement, à partir de la distribution du délai depuis le dernier paiement : même le quartile de clients les moins actifs, mais toujours engagés, présente une pause médiane de l'ordre de 55 à 60 jours ; 120 jours laisse donc une marge confortable au-delà d'une pause jugée normale. La durée de survie est ensuite construite entre la date de première activation (*dat_prem_paiement*) et soit la date de désengagement (client en événement), soit la date de référence (client censuré). Les résultats de ce modèle sont présentés au chapitre 7.

4.2.5 Classification des freins à l'usage

Contrairement aux cibles précédentes, cette classification n'a pas besoin d'être construite : elle existe déjà, sous la forme de la variable *alerte_metier* produite lors de la segmentation renforcée présentée au chapitre 5, pour la table 1 comme pour la table 2. Il s'agit d'une classification multi-étiquette, chaque client pouvant cumuler plusieurs freins simultanément, construite par combinaison de règles à partir des segments déjà calculés plutôt que par un modèle supervisé.

Pour la table 1, un client est signalé lorsque son segment de paiement et son segment de cash ou sa maturité digitale se combinent de façon défavorable ou atypique : « Paiement fort mais digital faible » (paiement fort et maturité digitale faible), « Client très orienté cash » (paiement faible et cash fort), « Grand utilisateur multi-flux » (paiement fort et cash fort) et « Faible usage global » (paiement faible et cash faible). Pour la table 2, la logique est similaire mais tournée vers les freins à l'activation : « Fort potentiel mais digital faible », « Faible potentiel très cash », « Activation difficile car cash fort » et « Aucune connexion app » (absence totale d'usage digital observé).

Cette classification étant déjà disponible, l'effort de préparation ne porte pas sur sa construction mais sur son rattachement à la base analytique : la variable *alerte_metier* sera jointe à la base du modèle de classification actif / jamais actif par l'identifiant client, afin de pouvoir être exploitée soit comme variable explicative complémentaire, soit comme grille de lecture pour interpréter les erreurs de classification du futur modèle.

4.2.6 Scoring commerçant

Contrairement aux cibles précédentes, définies au niveau client, cette dernière cible impose un changement de granularité : il ne s'agit plus de qualifier un client mais un commerçant. La table 1 ne contient pas de table commerçant à part entière, mais un champ indiquant, pour chaque client, le commerçant représentant sa plus forte dépense sur l'année (*ens_pv_top_depense_2025*). La préparation de cette base consiste donc à regrouper les clients par ce commerçant, plutôt qu'à construire une nouvelle variable cible au sens strict.

4.2.6.1 Nettoyage du nom de commerçant

Le champ *ens_pv_top_depense_2025* présente initialement 12 363 valeurs distinctes pour 50 000 clients, mais une partie de cette variété provient de doublons de saisie plutôt que de commerçants

réellement différents : « CARREFOUR MARKE » et « Carrefour Marke » désignent par exemple le même commerçant. Une harmonisation de la casse et des espaces superflus ramène le nombre de commerçants distincts à 12 318. Cette harmonisation reste toutefois partielle : des variantes plus profondes, comme « TEMU » et « TEMU.COM », ne sont pas fusionnées automatiquement, faute d’une règle de rapprochement fiable qui ne risquerait pas de regrouper à tort des commerçants distincts. Les 633 clients sans commerçant renseigné sont écartés de cette préparation.

4.2.6.2 Agrégation au niveau commerçant

Pour chaque commerçant, les clients qui le désignent comme leur première destination de dépense sont regroupés afin de calculer : le nombre de clients rattachés, leur fréquence et leur volume de paiement moyens, leur usage digital moyen, leur ancienneté moyenne, ainsi que la part de clients classés « Grand utilisateur multi-usage » dans la segmentation renforcée – utilisée ici comme indicateur de la qualité de la clientèle attirée par ce commerçant.

Une limite méthodologique importante doit être soulignée : le volume agrégé par commerçant correspond au volume de paiement **total** des clients qui le désignent comme première destination de dépense, et non au chiffre d’affaires réellement encaissé par ce commerçant. Les données ne permettent pas de connaître le montant dépensé spécifiquement chez chaque commerçant, transaction par transaction : ce score doit donc être lu comme un indicateur de la valeur des clients attirés par un commerçant, non comme une mesure directe de son activité commerciale.

Par ailleurs, la répartition des clients par commerçant est très inégale : la majorité des 12 318 commerçants ne comptent que quelques clients, ce qui rend un score peu fiable statistiquement. Un seuil minimal de 30 clients a donc été retenu pour distinguer les commerçants dont le score peut être interprété avec confiance : 177 commerçants dépassent ce seuil, représentant 19 784 clients.

Les résultats de ce classement seront présentés et interprétés dans le chapitre consacré à la modélisation prédictive et aux recommandations.

Conclusion

Ce chapitre a précisé la granularité retenue pour la base analytique – une ligne par client – et défini les six cibles mobilisées pour la suite du projet : la propension à la montée en usage et à la première activation, l’activation à J+30 reformulée en étude rétrospective, la classification actif / jamais actif, le délai avant activation et le désengagement, la classification des freins à l’usage et le scoring commerçant. Ce travail de préparation, mené dans le respect des contraintes de comparabilité entre les deux tables, sert de socle aux résultats présentés dans les trois chapitres suivants.

Chapitre 5

Segmentation comportementale

Introduction

Nous présentons dans ce chapitre la démarche de segmentation retenue pour analyser la clientèle étudiée. L'objectif est d'identifier des groupes homogènes de clients selon leurs comportements transactionnels, afin de mieux comprendre les usages observés et de préparer l'application de méthodes d'analyse plus avancées. Nous construisons d'abord cette segmentation à partir de règles métier, avant de l'enrichir par une lecture comparative des deux tables étudiées puis par des méthodes non supervisées.

Rappelons que les deux tables ne relèvent pas de la même logique : la première concerne des clients déjà actifs ou partiellement actifs dans le paiement, tandis que la seconde regroupe des clients n'ayant pas encore adopté le paiement carte.

5.1 Cadre méthodologique de la segmentation

5.1.1 Pourquoi segmenter, et pourquoi par règles métier

Une lecture globale et uniforme de la clientèle ne suffit pas : les usages, les niveaux d'activité et les profils transactionnels varient trop fortement d'un client à l'autre pour être résumés par une moyenne. Segmenter permet de structurer cette diversité en sous-ensembles cohérents et exploitables, un enjeu particulièrement fort dans un contexte bancaire où la compréhension fine des comportements clients conditionne la qualité des décisions commerciales. C'est aussi une étape préparatoire indispensable avant d'aller plus loin : en organisant les données en groupes homogènes, nous posons une base de travail plus stable pour les analyses complémentaires menées plus loin dans ce chapitre (clustering, réduction de dimension, analyse de stabilité).

Nous avons choisi de construire cette première segmentation à partir de règles métier plutôt que d'un algorithme non supervisé dès le départ. Une segmentation entièrement algorithmique détecte bien les structures latentes des données, mais elle reste souvent difficile à traduire en leviers d'action concrets pour un lecteur métier. Une approche par règles, elle, s'appuie sur des dimensions directement compréhensibles – intensité d'usage, fréquence transactionnelle, comportement cash, maturité digitale – et respecte la logique propre à chacune des deux tables : usages déjà observés pour la première, potentiel d'activation pour la seconde. Les seuils sont construits à partir des quantiles de la distribution réelle des données plutôt que fixés arbitrairement, ce qui garantit une base empirique solide. Cette segmentation par règles constitue ainsi une première structuration de la clientèle, lisible et directement mobilisable, que nous renforçons ensuite par des techniques statistiques.

5.1.2 Deux tables, deux logiques d'analyse

La table 1 regroupe des clients dont le comportement transactionnel permet d'observer des usages déjà installés, en particulier autour du paiement et des retraits : elle relève d'une logique d'**usage observé**. La table 2, à l'inverse, concerne des clients qui n'ont pas encore adopté le paiement carte ; nous ne pouvons donc pas y analyser un usage existant, mais plutôt des indicateurs de **potentiel d'activation** – la propension du client à évoluer vers un usage plus actif du paiement. Cette différence de nature impose d'adapter à la fois le choix des variables et l'interprétation des résultats : la première table nous permet de décrire et structurer des comportements existants, la seconde d'anticiper des

trajectoires d'adoption. Les deux lectures sont complémentaires plutôt que redondantes – l'une éclaire les usages réalisés, l'autre les marges de progression.

5.2 Construction de la segmentation de la table 1

5.2.1 Objectif

Nous cherchons ici à structurer la clientèle à partir des comportements transactionnels effectivement observés, autour du paiement et des retraits. Contrairement à une logique de potentiel, cette segmentation repose sur des pratiques déjà réalisées par les clients et vise à faire apparaître des groupes homogènes selon l'intensité et la nature de leur activité. Nous retenons pour cela deux axes : un axe de paiement (fréquence, volume, diversité, usage digital, ancienneté) et un axe cash (fréquence des retraits, volume, orientation générale vers le cash), afin de dépasser la simple opposition actif/inactif et de faire ressortir des combinaisons de comportements plus fines.

5.2.2 Variables retenues

Le tableau suivant liste les huit variables mobilisées pour cette segmentation, réparties entre l'axe de paiement, l'axe cash et la dimension digitale, avec pour chacune le rôle qu'elle joue dans l'analyse et la justification de son choix.

Variable	Axe de segmentation	Rôle dans l'analyse	Justification du choix
Fréquence des paiements	Paie-ment	Mesure l'intensité d'usage du paiement	Permet d'identifier les clients les plus actifs sur le plan transactionnel.
Volume des paiements	Paie-ment	Mesure l'importance monétaire des paiements	Complète la fréquence en captant l'ampleur réelle de l'activité de paiement.
Diversité des paiements	Paie-ment	Mesure la variété des comportements de paiement	Permet de distinguer les clients ayant un usage plus équilibré entre plusieurs canaux ou types de flux.
Usage digital	Digital	Mesure la maturité digitale	Indique le niveau d'adoption des canaux numériques et la propension à utiliser des services dématérialisés.
Ancienneté relationnelle	Historique	Mesure la profondeur de la relation client	Sert à apprécier la stabilité de la relation bancaire et le degré de maturité du client dans le temps.
Fréquence des retraits	Cash	Mesure l'intensité de l'usage du cash	Permet de repérer les clients qui réalisent régulièrement des retraits.
Volume des retraits	Cash	Mesure l'importance du cash dans les flux	Complète la fréquence des retraits en donnant une lecture plus fine de la dépendance au cash.
Orientation cash	Cash	Mesure le poids relatif du cash	Permet d'identifier les profils davantage orientés vers les retraits que vers les paiements dématérialisés.

TABLE 5.1 – Variables retenues pour la segmentation de la table 1 et justification de leur choix

Ces variables couvrent les dimensions les plus structurantes du comportement client : intensité d'usage, valeur des flux, orientation cash et maturité digitale. D'autres variables ont été observées en cours d'analyse mais écartées de la segmentation principale, pour éviter la redondance et préserver la lisibilité de la structure obtenue.

5.2.3 Construction des scores et des seuils

Nous résumons ces variables en trois scores synthétiques – paiement, cash et maturité digitale – plutôt que de manipuler directement chaque indicateur élémentaire.

Une fois ces scores calculés, nous fixons les seuils de segmentation à partir des quantiles – les 25e et 75e percentiles – pour répartir la population en trois catégories : faible, moyen et fort. Cette

Score	Variables mobilisées	Mode de calcul	Rôle dans la segmentation
Score de paiement	Fréquence des paiements, volume des paiements, diversité des usages, usage digital, ancienneté relationnelle	Combinaison pondérée des variables après normalisation, afin de résumer l'intensité et la richesse du comportement de paiement	Identifier les clients les plus actifs sur le plan des paiements et distinguer les profils dominants en matière d'usage
Score de cash	Fréquence des retraits, volume des retraits, orientation générale vers le cash	Combinaison pondérée des variables après normalisation, afin de mesurer le poids du cash dans le comportement transactionnel	Repérer les clients les plus orientés vers les retraits et mesurer leur dépendance aux opérations cash
Score digital	Nombre de connexions à l'application	Variable isolée puis classée par quantiles, afin de mesurer le degré de maturité digitale	Évaluer le niveau d'adoption des canaux numériques et compléter la lecture des comportements transactionnels

TABLE 5.2 – Construction des scores utilisés pour la segmentation de la table 1

approche s'appuie sur la distribution réelle des données plutôt que sur des bornes arbitraires, tout en gardant une segmentation équilibrée et facile à interpréter. Sur la table 1, le score de paiement de la zone intermédiaire est ainsi compris entre 0,2348 et 0,4347, et le score de cash entre 0,5908 et 0,7550.

5.2.4 Segmentation principale : paiement et cash

Le croisement du score de paiement et du score de cash offre une vision plus nuancée que la seule opposition actif/inactif, en distinguant les profils équilibrés, les clients davantage orientés paiement, et ceux dont l'activité reste marquée par le cash. Chaque client est classé faible, moyen ou fort sur chacun des deux axes, ce qui produit une matrice de neuf combinaisons. La distribution est parfaitement équilibrée au niveau marginal : 12 500 clients dans les segments faibles et forts pour chaque axe, 25 000 dans le segment intermédiaire.

Le segment le plus important est celui des utilisateurs mixtes équilibrés, avec 15 606 clients – une population où paiement et cash coexistent sans domination nette d'un axe sur l'autre. D'autres segments ressortent de façon significative, comme les grands utilisateurs multi-usage ou les utilisateurs cash dominants, tandis que le segment cash intensif reste marginal (40 clients). Les combinaisons les plus fréquentes se situent dans les niveaux intermédiaires ou élevés des deux axes (paiement moyen + cash moyen, paiement fort + cash fort), alors que des combinaisons comme paiement faible + cash fort restent rares – un profil transactionnel atypique.




FIGURE 5.1 – Distribution des scores et seuils de segmentation retenus




FIGURE 5.2 – Matrice croisée des segments : Score de paiement × Score de cash

5.2.5 Segmentation renforcée

Le segment paiement fort reste hétérogène : il regroupe des clients aux profils très différents selon la répartition de leurs paiements entre local et international. Nous l'affinons donc en cinq profils : 100 % local, 100 % international, local dominant, international dominant et mixte, à partir de la présence de paiements locaux/internationaux et de leur part relative en volume et en nombre.

Le sous-segment le plus important est celui des paiements forts mixtes (5 153 clients), suivi des profils local dominant et 100 % local ; les profils international dominant et 100 % international restent beaucoup plus restreints, révélant une forte asymétrie entre usage local et international au sein des paiements forts. Cette hétérogénéité confirme que le segment fort n'est pas un bloc homogène et qu'il justifie une lecture plus détaillée, faisant au passage ressortir des profils rares mais potentiellement stratégiques, comme les clients à paiement international très élevé.




FIGURE 5.3 – Répartition des sous-segments de paiement fort

5.3 Construction de la segmentation de la table 2

5.3.1 Objectif

Nous cherchons ici à identifier, parmi les clients qui n'ont pas encore adopté le paiement carte, ceux qui présentent le plus fort potentiel d'activation : il ne s'agit plus de décrire un usage installé, mais d'anticiper les profils les plus susceptibles d'évoluer vers ce mode de paiement. Cette lecture constitue une base opérationnelle pour hiérarchiser les efforts d'animation commerciale et distinguer les clients facilement activables de ceux dont l'orientation cash ou le faible usage digital compliquent l'activation.

5.3.2 Variables retenues et logique de potentiel

Trois axes structurent cette segmentation : le potentiel d'activation (intensité des flux, fréquence transactionnelle, montant entrant, usage digital, ancienneté), l'orientation cash (place des retraits dans les flux sortants) et la maturité digitale (usage de l'application). Ces variables captent chacune une dimension complémentaire du comportement : le niveau d'activité, la dynamique des flux, la dépendance au cash et la capacité à interagir avec des canaux dématérialisés – l'ancienneté apportant en plus un signal de profondeur relationnelle.

Les quantiles observés confirment des distributions suffisamment contrastées pour segmenter de façon lisible : l'intensité des flux passe de 5 800 au premier quartile à 66 168,37 au troisième, l'usage digital de 94 à 168 entre P25 et P75, et l'ancienneté médiane s'établit à 39 mois – une population déjà installée dans la relation bancaire, mais avec des niveaux de maturité et d'activité très hétérogènes. Nous appliquons la même règle de seuillage que pour la table 1 : faible en dessous de P25, moyen entre P25 et P75, fort au-dessus de P75, pour le score de potentiel d'activation, le score d'orientation cash et l'usage digital.

5.3.3 Construction du score de potentiel d'activation

Ce score synthétise les dimensions qui traduisent la capacité d'un client à évoluer vers le paiement carte : activité bancaire, maturité digitale et ancienneté relationnelle. Un score élevé traduit une combinaison d'activité soutenue, d'usage digital déjà présent et d'une relation bancaire suffisamment installée ; un score faible signale au contraire une intensité relationnelle limitée ou des freins structurels. Les quantiles observés situent ce score entre 0,3502 (P25) et 0,5269 (P75), avec une médiane à 0,4115.

5.3.4 Segmentation principale

Le croisement du potentiel d'activation et de l'orientation cash permet de ne pas se limiter à un score unique et de distinguer des sous-populations aux comportements très différents en matière d'activabilité. La répartition fait apparaître trois blocs de potentiel : 15 000 clients à potentiel faible, 30 000 à potentiel moyen, 15 000 à potentiel fort ; et pour l'orientation cash, 12 310 clients en orientation faible, 33 148 en orientation moyenne, 14 542 en orientation forte.

Le groupe le plus important de la matrice croisée est potentiel moyen + orientation cash moyenne (19 233 clients) – le profil intermédiaire à travailler, ni prioritaire ni fermé à l'activation. Deux ensembles se distinguent ensuite : potentiel fort + orientation cash forte (7 662 clients, un fort potentiel

encore très marqué par le cash) et potentiel fort + orientation cash faible (4 209 clients, la cible prioritaire à activer, qui combine bon socle relationnel et freins cash limités). Les potentiels faibles se concentrent surtout en potentiel faible + orientation cash moyenne (10 786 clients), loin devant potentiel faible + orientation cash faible (3 959) et potentiel faible + orientation cash forte, résiduel (255 clients) – signe que les faibles potentiels ne sont pas uniformes : certains restent peu actifs sans dépendre du cash, d’autres sont plus nettement bloqués par les retraits. Cette matrice se double d’une nomenclature métier à neuf profils que nous réutilisons plus loin dans ce chapitre ; elle ajoute notamment « Profil cash à convertir » (6 625 clients) et « Cible à activer avec accompagnement » (3 129 clients) aux profils déjà identifiés.

5.3.5 Segmentation renforcée

Nous affinons ensuite les clients à fort potentiel en profils plus actionnables, pour distinguer ceux qui sont déjà proches d’une activation de ceux que le cash ou le digital freinent encore. Cinq sous-segments en ressortent : « Fort potentiel mais ancré cash » (7 662 clients, le plus important – flux élevés mais orientation cash quasi totale), « Fort potentiel mixte » (3 499 clients, orientation cash moins extrême, cible intermédiaire pour une activation progressive), « Fort potentiel digitalisable » (2 256 clients, flux élevés mais maturité digitale plus faible) et son pendant « Fort potentiel digital prêt à activer » (1 118 clients, profils déjà connectés et donc plus immédiatement mobilisables), et enfin « Fort potentiel orienté virement » (465 clients seulement, mais un profil transactionnel très favorable à une activation directe).

Les alertes métier confirment cette lecture : la grande majorité des clients (47 906) ne déclenche « Aucune alerte », mais parmi ceux qui en portent une, les cas les plus fréquents sont « Activation difficile car cash fort » et « Aucune connexion app », certaines combinaisons cumulant plusieurs freins à la fois (par exemple « Fort potentiel mais digital faible » associé à « Activation difficile car cash fort »). Cette couche d’alertes ajoute une dimension opérationnelle : elle identifie non seulement les segments porteurs, mais aussi les obstacles concrets à lever.

5.4 Analyse comparative des deux segmentations

Les deux segmentations répondent à des logiques complémentaires mais distinctes : la table 1 décrit des comportements déjà observables, la table 2 anticipe un potentiel d’activation chez des clients qui n’ont pas encore adopté le paiement carte. Dans la première, la segmentation structure des usages existants ; dans la seconde, elle repère des opportunités commerciales et anticipe une évolution possible des comportements – une logique descriptive d’un côté, prospective de l’autre. Les mêmes types de critères (orientation cash, digital, intensité des flux) n’y sont donc pas lus de la même façon : ils caractérisent un usage déjà constitué sur la table 1, et estiment une faisabilité d’activation sur la table 2.

Cette complémentarité est directement utile à la décision opérationnelle : les segments de la table 1 aident à comprendre les profils déjà actifs, ceux de la table 2 à cibler les campagnes de conversion, d’accompagnement ou de relance. Les deux lectures ne se superposent pas, elles se répondent – l’une décrit le présent des usages, l’autre prépare leur évolution.

5.4.1 Forces et limites de la segmentation métier

Cette segmentation par scores fournit une lecture stable et interprétable, mais elle reste fondée sur des règles définies a priori. Cette limite justifie l’ouverture vers des méthodes complémentaires, pour tester la structure réelle des données, repérer d’éventuels comportements atypiques et vérifier la robustesse des segments sur les deux tables – à la fois pour confronter la lecture métier à des approches statistiques non supervisées, et pour comparer plus librement les profils des deux tables.

5.4.2 Segmentation RFM

La segmentation RFM (Récence, Fréquence, Montant) est une base méthodologique simple et largement répandue pour décrire le comportement client à partir de trois dimensions. Elle transforme des données transactionnelles brutes en groupes facilement interprétables, avec une forte dimension opérationnelle : en attribuant un score à chaque client selon son activité récente, sa régularité d’usage et la valeur de ses opérations, elle permet d’identifier rapidement les profils prioritaires, à fort potentiel ou peu actifs. Elle reste cependant fondée sur des seuils a priori, donc moins souple qu’un clustering purement piloté par les données.

Dans ce mémoire, nous utilisons la logique RFM comme point d’ancrage commun aux deux tables, avant d’appliquer les méthodes plus exploratoires présentées dans la section suivante : K-Means, DBSCAN et réduction de dimension pour la visualisation.

5.5 Ouverture vers les méthodes complémentaires

5.5.1 Pourquoi enrichir la lecture métier

La segmentation métier repose sur des seuils fixés a priori à partir des quantiles P25 et P75 : elle capture des ruptures statistiques dans la distribution des scores, sans garantir que ces ruptures correspondent à une structure réelle et homogène des données. Nous confrontons donc cette lecture à une approche qui ne présuppose aucun découpage, pour vérifier si les groupes obtenus par les règles se retrouvent naturellement dans l’espace des variables comportementales, ou si d’autres structures, non anticipées par les règles, existent également. Cette démarche répond à un double objectif : valider la robustesse de la segmentation métier en mesurant dans quelle mesure ses segments coïncident avec des regroupements purement statistiques, et détecter les profils que la logique par seuils ne peut pas isoler – en particulier les comportements rares ou extrêmes qui se diluent dans les catégories « faible / moyen / fort ».

5.5.2 Méthodes retenues

Nous mobilisons trois méthodes complémentaires : le clustering K-Means, le clustering par densité DBSCAN, et la réduction de dimension pour la visualisation.

Les deux méthodes de clustering s’appuient sur un même socle de neuf variables comportementales non redondantes, propres à chaque table mais construites selon le même principe (ancienneté relationnelle, intensité et volume des flux, orientation cash, usage digital). Nous excluons volontairement les scores composites déjà utilisés pour la segmentation par règles (score de paiement et de cash pour la table 1, score de potentiel d’activation et d’orientation cash pour la table 2) : ces scores étant

eux-mêmes des agrégats de ces variables, les réintroduire dans le clustering créerait une circularité et biaiserait la comparaison entre les deux approches. Les variables retenues sont winsorisées au 1er et au 99e centile puis standardisées avant tout traitement. Les clients présentant une valeur manquante sur au moins une de ces variables sont exclus de cette analyse : 49 367 clients sur 50 000 sont conservés pour la table 1, et 56 113 sur 60 000 pour la table 2. Les effectifs par segment métier cités plus loin portent donc sur ces sous-populations, et peuvent différer légèrement des totaux présentés plus haut, calculés sur l'ensemble de la population.

Pour **K-Means** [MacQueen, 1967], nous testons un nombre de clusters variant de 2 à 7, avec sélection par croisement de l'inertie (méthode du coude) et du score de silhouette. Pour ne pas nous limiter à l'optimum statistique brut, qui tend à privilégier un partitionnement très grossier sur ce type de données, nous conservons deux lectures : l'optimum global au sens du silhouette, et le meilleur compromis parmi les solutions à trois clusters ou plus, jugé plus actionnable sur le plan métier. Nous vérifions ensuite la robustesse du partitionnement retenu par une analyse de stabilité : dix relances de K-Means avec des graines aléatoires différentes, dont nous mesurons l'accord par l'Adjusted Rand Index (ARI) [Hubert and Arabie, 1985].

DBSCAN [Ester et al., 1996] sert une logique différente : non pas partitionner l'ensemble de la population, mais isoler les comportements atypiques que K-Means, en cherchant à minimiser une inertie globale, tend à absorber dans les clusters les plus proches. Nous fixons *min_samples* selon la règle usuelle de deux fois le nombre de dimensions, et déterminons *eps* automatiquement à partir du graphe des k-distances, en retenant le point de coude le plus éloigné de la droite reliant les deux extrémités de la courbe.

Enfin, la **réduction de dimension** combine deux méthodes : une analyse en composantes principales (PCA) [Pearson, 1901], qui préserve au mieux la variance globale et reste interprétable, et une projection UMAP [McInnes et al., 2018], plus adaptée à la mise en évidence de structures locales et de sous-groupes compacts. Nous utilisons les deux projections aussi bien pour K-Means que pour DBSCAN.

5.5.3 Résultats du clustering K-Means sur la première table

Pour la table 1, le socle de neuf variables regroupe : ancienneté relationnelle, fréquence et volume de paiement, diversité des paiements, part des paiements locaux, fréquence et volume des retraits, part des paiements dans l'activité globale, et usage digital.

Le score de silhouette est maximal pour deux clusters (0,477), diminue pour trois (0,358), puis remonte légèrement pour quatre (0,379) avant de redescendre. Cette forme non monotone est cohérente avec la structure de la population : une rupture statistique très nette sépare un petit groupe de clients à forte intensité transactionnelle du reste de la population, ce qui favorise mécaniquement un optimum à deux clusters, au détriment d'une lecture plus fine de la masse intermédiaire.

La partition à deux clusters isole un groupe de 5 865 clients (11,9 % de la population), caractérisé par une ancienneté élevée, une fréquence de paiement de 248,6 opérations en moyenne, un volume de paiement de 97 921 en moyenne, une fréquence et un volume de retraits nettement supérieurs à la moyenne, et un usage digital élevé (505,6 connexions en moyenne). Ce cluster est composé à 83,7 % de clients du segment « Grand utilisateur multi-usage » (4 909 clients sur 5 865) et capture 69,3 %

de l'ensemble de ce segment (4 909 sur 7 083) : une validation solide par une méthode entièrement indépendante des règles, même si environ un tiers des grands utilisateurs se retrouve malgré tout mélangé au reste de la population dans le second cluster (43 502 clients, sans distinction fine). Cette partition est en outre extrêmement stable : l'ARI moyen entre dix graines aléatoires atteint 0,999 (écart-type 0,001) – la frontière entre grands utilisateurs et reste de la population ne dépend donc pas de l'initialisation de l'algorithme.

La lecture à quatre clusters, retenue comme second niveau de détail, affine sensiblement cette structure :

- un cluster de 3 935 clients (8,0 %) qui isole plus finement les grands utilisateurs multi-usage, avec les valeurs moyennes les plus élevées sur pratiquement toutes les variables ;
- un cluster de 31 924 clients (64,7 %) qui regroupe la masse des utilisateurs cash dominants, cash occasionnels et mixtes équilibrés, avec une part de paiement très faible (3 %) et des paiements exclusivement locaux ;
- un cluster de 3 213 clients (6,5 %) au profil inattendu : une part de paiement de 94 % (quasiment aucun retrait), mais l'usage digital le plus faible des quatre clusters (136,9 connexions en moyenne) – des clients qui paient presque exclusivement par carte sans être engagés sur le canal digital, un profil que la segmentation métier ne nomme pas explicitement ;
- un cluster de 10 295 clients (20,9 %) marqué par la diversité de paiement la plus élevée (1,78) et une répartition équilibrée entre local et international (51 % de paiements locaux) – le seul cluster où l'usage international est réellement significatif.

Le croisement du troisième cluster (paiement pur, digital faible) avec la segmentation métier montre qu'il se répartit entre « Utilisateur digital en progression » (41,6 %), « Faible utilisateur global » (39,5 %) et, dans une moindre mesure, « Utilisateur paiement prioritaire » (19,0 %) : trois segments distincts au sens des règles, mais qui partagent visiblement un même déficit d'engagement digital – le libellé même du segment « digital en progression » confirme un usage encore limité, cohérent avec le profil du cluster. Cette lecture, invisible dans la segmentation par règles, constitue un apport propre au clustering.

5.5.4 Détection des comportements atypiques par DBSCAN sur la première table

Avec un *eps* de 1,024 et un *min_samples* de 18, déterminés automatiquement à partir du graphe des k-distances, DBSCAN fait émerger quatre clusters denses et un ensemble de 4 854 clients (9,83 %) classés comme bruit – des comportements atypiques qui ne s'intègrent à aucune zone dense de l'espace des variables.

Le cluster dense principal (33 737 clients, 68,3 %) recoupe la même masse cash-dominante et mixte déjà identifiée par K-Means. Deux clusters plus spécifiques se distinguent nettement : 7 769 clients à diversité de paiement élevée et part locale de 67 %, et 2 949 clients dont la part locale est nulle – des paiements intégralement réalisés à l'international, un profil invisible pour K-Means, qui illustre bien l'intérêt d'une méthode fondée sur la densité : un sous-groupe homogène mais peu nombreux peut être noyé dans un cluster plus large par K-Means, alors qu'il forme une zone dense identifiable pour DBSCAN.

Le résultat le plus notable reste un quatrième cluster de seulement 58 clients, aux moyennes extrêmes sur toutes les dimensions : 665 paiements en moyenne pour un volume de 296 605, une




FIGURE 5.4 – Projection PCA des quatre clusters K-Means (table 1)




FIGURE 5.5 – Projection UMAP des quatre clusters K-Means (table 1)

fréquence de retraits moyenne dépassant 71 000 opérations et un volume de retraits moyen supérieur à 109 millions. Ce micro-segment, entièrement rattaché au segment métier « Grand utilisateur multi-usage » (58 clients sur 58), correspond à une clientèle à très haute valeur que K-Means, contraint de répartir toute la population en un nombre restreint de groupes, ne parvenait pas à isoler aussi nettement du reste des grands utilisateurs. Sa fréquence de retraits, très supérieure à ce qu'un usage individuel plausible laisserait attendre, tient à quelques valeurs extrêmes déjà présentes dans les données sources (le maximum observé sur l'ensemble de la table 1 atteint 305 558 retraits pour un même client) et mériterait d'être vérifiée auprès de la source des données avant toute exploitation commerciale directe.

Le groupe des 4 854 clients atypiques recoupe à 70,3 % le segment « Grand utilisateur multi-usage » (3 411 clients), mais inclut aussi une part notable d'« Utilisateur paiement prioritaire » (516 clients sur 1 135, près de la moitié de ce segment). Ce recouvrement partiel confirme que le bruit détecté par DBSCAN ne se limite pas à des erreurs ou des valeurs aberrantes : il capture une frange de clients au comportement suffisamment singulier pour ne s'apparenter pleinement à aucun profil dominant, qu'il s'agisse d'une lecture par règles ou par densité.




FIGURE 5.6 – Graphe des k-distances et sélection du paramètre eps pour DBSCAN

5.5.5 Résultats du clustering K-Means sur la deuxième table

Nous reproduisons la même démarche sur la table 2, avec un socle de neuf variables construites sur le même principe : ancienneté relationnelle, montant et fréquence des flux entrants, montant et fréquence des retraits, montant et fréquence des virements sortants, part des retraits dans les flux sortants, et usage digital. Les scores métier et les segments qui en découlent en sont là aussi exclus, pour la même raison de circularité.




FIGURE 5.7 – Clusters denses et comportements atypiques détectés par DBSCAN (projection PCA)

Le score de silhouette est ici maximal pour deux clusters (0,607) – un optimum plus net que sur la table 1 – avant de diminuer pour trois et quatre clusters (0,430 puis 0,450) et de remonter localement à cinq (0,477). La partition à deux clusters isole 4 710 clients (8,4 %) aux flux entrants et sortants nettement supérieurs à la moyenne (montant entrant moyen de 347 831, virements sortants de 300 910) et à l’orientation cash modérée (45 % de la sortie en retraits). Ce cluster capture 68,9 % du segment « Cible prioritaire à activer » (2 827 clients sur 4 101) – une validation forte, dans la même logique que le « Grand utilisateur multi-usage » de la table 1 – et se révèle tout aussi stable, avec un ARI moyen de 0,997 (écart-type 0,003) sur dix graines aléatoires.

La lecture à cinq clusters affine cette structure :

- un cluster de 1 683 clients (3,0 %) aux flux extrêmes (montant entrant moyen de 701 682, virements sortants de 665 697), composé à 89,6 % de clients « Cible prioritaire à activer » (1 507 sur 1 683) ;
- un cluster de 5 062 clients (9,0 %) orienté virement plutôt que retrait (part de retrait de 15 %), qui recoupe surtout « Profil cash à convertir » (51,2 %) et « Cible prioritaire à activer » (36,7 %) ;
- un cluster de 10 065 clients (17,9 %) au profil inverse, très orienté retrait (94 %) mais avec un montant entrant non négligeable, qui recoupe majoritairement « Potentiel fort mais réflexe cash » (57,6 %) ;
- un cluster de 38 301 clients (68,3 %), le plus large, qui regroupe la masse des profils à faible activité et forte orientation cash (99 % de retrait) ;
- un cluster de 1 002 clients (1,8 %) au profil inattendu : un usage digital moyen de 1 324 connexions, près de dix fois supérieur aux autres clusters, pour des flux par ailleurs modérés. Ce profil hyper-digital se disperse entre plusieurs segments métier, ce qui suggère une dimension à part, non capturée par la logique de potentiel d’activation des règles.




FIGURE 5.8 – Projection PCA des cinq clusters K-Means (table 2)




FIGURE 5.9 – Projection UMAP des cinq clusters K-Means (table 2)

5.5.6 Détection des comportements atypiques par DBSCAN sur la deuxième table

La sélection automatique d'*eps* par le coude du graphe des k-distances a demandé un ajustement sur la table 2 : le coude calculé sur la courbe brute ($eps \approx 1,29$) provoquait une saturation mémoire à l'exécution de DBSCAN, la zone centrale de l'espace standardisé étant trop dense. Nous avons donc écarté le dernier centile de la courbe – les points les plus isolés, de toute façon destinés à finir en bruit – avant de rechercher le coude, ce qui ramène *eps* à 0,712 pour un *min_samples* de 18. Cet ajustement ne change rien à la logique de la méthode, il évite simplement que quelques points extrêmes ne biaisent le choix du paramètre.

Avec ces paramètres, DBSCAN fait émerger six clusters denses et 9 326 clients atypiques (16,6 %). Le cluster dense principal (45 913 clients, 81,8 %) correspond à la masse à faible activité déjà identifiée par K-Means. Les cinq autres, beaucoup plus petits, sont fortement caractérisés : 657 clients à usage digital très élevé (1 298 connexions en moyenne), qui confirment indépendamment le profil hyper-digital déjà repéré par K-Means ; 95 clients quasi exclusivement tournés vers le retrait (montant moyen de 535 246) ; et surtout 68 clients au profil extrême, entièrement tournés vers le virement (part de retrait nulle), avec un montant entrant moyen de 2,3 millions et des virements sortants moyens de 2,4 millions. Ce dernier micro-segment recoupe intégralement « Cible prioritaire à activer » (68 clients sur 68) – avec son équivalent de la table 1, l'un des résultats les plus nets de cette analyse : un noyau de clients à très haute valeur, invisible en tant que groupe homogène dans la segmentation par règles, mais clairement isolé par une méthode fondée sur la densité.

Le groupe des 9 326 clients atypiques présente ici un profil très différent de celui de la table 1 : plutôt que des comportements marginaux, il concentre 90,6 % du segment « Cible prioritaire à activer » (3 714 clients sur 4 101) et 52,8 % de « Cible à activer avec accompagnement » (1 653 sur 3 128). Ces clients à fort potentiel partagent un niveau d'activité élevé, mais des combinaisons de flux entrants, de retraits et de virements trop variées pour former une zone dense au sens de DBSCAN – un constat qui rejoint celui de la table 1, où le bruit recouvrait déjà en grande partie les profils les plus actifs. Sur les deux tables, DBSCAN tend donc à isoler les clients les plus engagés comme un ensemble hétérogène plutôt que comme un cluster unique, ce qui est un résultat cohérent et interprétable, pas une limite de la méthode.




FIGURE 5.10 – Graphe des k-distances et sélection du paramètre eps pour DBSCAN (table 2)




FIGURE 5.11 – Clusters denses et comportements atypiques détectés par DBSCAN (table 2, projection PCA)

Conclusion

Nous avons construit dans ce chapitre une segmentation comportementale complète de la clientèle, en combinant une approche par règles métier et un enrichissement par des méthodes non supervisées, appliquées selon la même méthodologie sur les deux tables. La segmentation par règles – scores de paiement, de cash et de maturité digitale – fournit une première lecture stable, interprétable et directement mobilisable, aussi bien pour la table 1 (usage observé) que pour la table 2 (potentiel

d'activation).

L'ouverture vers K-Means et DBSCAN confirme la robustesse de cette lecture sur ses segments les plus structurants : le « Grand utilisateur multi-usage » de la table 1 et la « Cible prioritaire à activer » de la table 2 forment tous deux la composante largement dominante d'un cluster extrêmement stable, retrouvé par une méthode entièrement indépendante des règles – même si une fraction de ces segments reste répartie ailleurs, ce qui invite à ne pas lire cette validation comme une correspondance parfaite. Elle met surtout au jour des profils que la segmentation par seuils ne pouvait pas isoler : sur la table 1, des payeurs à faible engagement digital malgré un usage de paiement favorable, et un profil de paiement exclusivement international ; sur la table 2, un profil hyper-digital retrouvé indépendamment par les deux méthodes, ainsi que des micro-segments de clients à très haute valeur, purement orientés virement ou purement orientés retrait. Sur les deux tables, le bruit détecté par DBSCAN s'est révélé riche d'enseignement : il concentre les clients au comportement le plus engagé, mais aussi le plus hétérogène.

Ces apports constituent une base directement exploitable pour affiner les recommandations commerciales du chapitre 7, en particulier pour prioriser les micro-segments à très haute valeur identifiés par DBSCAN et traiter séparément le profil hyper-digital, qui ne correspond à aucune des catégories définies par les règles métier initiales.

Chapitre 6

Étude de la vitesse d'activation et de la fidélité

Introduction

Ce chapitre présente les résultats de l'étude préparée au chapitre 4 : la comparaison, parmi les clients déjà activés de la table 1, du niveau d'engagement ultérieur selon la rapidité de leur première activation. Cette analyse reste descriptive et corrélacionnelle – elle ne permet pas d'établir un lien de causalité entre vitesse d'activation et fidélité – mais elle constitue une première lecture exploitable avec les données disponibles, et une base pour un futur modèle prédictif si un historique daté devient accessible.

6.1 Populations comparées

Sur les 50 000 clients de la table 1, 633 sont écartés pour dates manquantes et 2 588 (5,2 % de la table) pour délai d'activation négatif, un premier paiement enregistré avant le début officiel de la relation bancaire. Au total, 46 779 clients restent exploitables.

Trois groupes ont été constitués à partir du délai d'activation : activation rapide (30 jours ou moins, 6 057 clients), activation intermédiaire (entre 31 et 60 jours, 4 515 clients) et activation tardive (plus de 60 jours, 36 207 clients). La grande majorité des clients de la table 1 mettent donc plus de deux mois avant de réaliser leur premier paiement après l'ouverture de la relation.

6.2 Résultats

Le rythme de paiement mensuel médian diminue de façon monotone avec le délai d'activation : 1,66 paiement par mois pour les clients activés rapidement, contre 1,15 pour les activations intermédiaires et seulement 0,55 pour les activations tardives – soit un rythme environ trois fois plus élevé pour les activations rapides que pour les activations tardives. Le même ordre se retrouve sur l'usage digital médian (212 connexions pour les activations rapides, contre 184 pour les activations tardives), avec un écart moins marqué.

Cette tendance se confirme sur l'indicateur métier le plus direct : la part de clients classés « Grand utilisateur multi-usage » atteint 20,65 % parmi les activations rapides, contre 17,74 % pour les activations intermédiaires et seulement 13,44 % pour les activations tardives. Un client qui active son premier paiement dans le mois suivant l'ouverture de sa relation a donc, dans ces données, environ 1,5 fois plus de chances de devenir un grand utilisateur qu'un client qui met plus de deux mois à s'activer.

Le croisement complet avec les neuf segments d'usage confirme cette lecture : la part d'« Utilisateur paiement dominant » suit la même tendance décroissante (11,87 % puis 10,21 % puis 8,22 %), tandis que la part d'« Utilisateur cash occasionnel » augmente au contraire avec le délai d'activation (6,98 % puis 9,79 % puis 11,19 %). Autrement dit, les clients qui tardent à s'activer ne se contentent pas d'être globalement moins actifs : ils tendent aussi à rester durablement plus orientés vers le cash lorsqu'ils finissent par s'activer.




FIGURE 6.1 – Part de clients « Grand utilisateur multi-usage » selon la vitesse d'activation




FIGURE 6.2 – Rythme de paiement mensuel depuis l'activation, selon la vitesse d'activation

6.3 Désengagement réel par groupe de vitesse d'activation

Les résultats précédents reposent sur un indicateur de rythme d'usage, qui capture le volume d'activité mais ne dit rien du fait qu'un client ait, ou non, cessé de payer par carte. La date de dernier paiement, obtenue en cours de projet et déjà mobilisée pour construire le modèle de survie du désengagement (chapitres 4 et 7), permet de compléter cette lecture avec une mesure directe : un client est considéré désengagé si son dernier paiement remonte à plus de 120 jours à la date de référence du 31 décembre 2025, le même seuil que celui retenu pour ce modèle de survie.

Groupe	Clients	Médiane (j)	Moyenne (j)	Désengagement
Activation rapide ($\leq 30j$)	6 057	16	38,74	8,0 %
Activation intermédiaire (31–60j)	4 515	18	42,48	9,0 %
Activation tardive ($> 60j$)	36 207	21	50,39	13,0 %

TABLE 6.1 – Désengagement réel (seuil de 120 jours) selon la vitesse d'activation

Le taux de désengagement réel suit exactement l'ordre attendu – 8,0 % pour les activations rapides, contre 13,0 % pour les activations tardives, soit un risque environ 1,6 fois plus élevé – et confirme, avec un indicateur directement observé plutôt qu'un proxy construit sur le rythme d'usage, l'avantage de fidélité déjà mis en évidence par les résultats précédents. Le nombre médian de jours depuis le dernier paiement suit la même progression (16, 18 puis 21 jours), un écart plus modeste que celui du taux de désengagement, ce qui indique que l'essentiel de la différence entre groupes se joue sur la minorité de clients réellement désengagés plutôt que sur un ralentissement généralisé du rythme de paiement des clients encore actifs.

6.4 Commerçant principal selon la vitesse d'activation

La table 1 indique, pour chaque client, le commerçant de plus forte dépense sur l'année 2025 (*ens_pv_top_depense_2025*, déjà mobilisé pour le scoring commerçant du chapitre 7). Il ne s'agit pas du commerçant du premier paiement – les données ne permettent pas de dater chaque transaction individuellement – mais ce croisement permet néanmoins de vérifier si le profil de consommation diffère selon la vitesse d'activation.

Glovo domine nettement le classement des activations rapides et intermédiaires : il concentre 6,1 % des clients activés rapidement (368 sur 6 057) et 4,7 % des activations intermédiaires, devant ONCF E-commerce et Carrefour Market. Pour les activations tardives, en revanche, ce classement s'inverse : Carrefour Market (949 clients) et ONCF E-commerce (879) devancent Glovo (658), qui ne représente plus que 1,8 % de ce groupe, beaucoup plus nombreux. Le poids relatif de Glovo diminue donc à mesure que le délai d'activation augmente, ce qui rejoint le constat du chapitre 7 : la clientèle de Glovo est associée à un usage carte nettement plus engagé que la moyenne, un profil que l'on retrouve logiquement surreprésenté parmi les clients qui se sont activés le plus vite.

6.5 Profils au sein de l'activation tardive

Le groupe « activation tardive » représente à lui seul 77,4 % des clients exploitables de ce chapitre (36 207 sur 46 779), et affiche en moyenne le rythme d'usage le plus faible. Reste à savoir s'il s'agit

d'une masse homogène de clients peu engagés, ou si ce groupe recouvre en réalité des profils différents. Un DBSCAN restreint à ce seul groupe, avec les mêmes neuf variables comportementales et la même recette que la segmentation renforcée du chapitre 5 (winsorisation, standardisation, *eps* et *min_samples* déterminés automatiquement par la méthode du coude), permet de trancher.

L'algorithme identifie 5 clusters denses et 9,49 % de comportements atypiques (3 436 clients, aux valeurs extrêmes sur plusieurs variables à la fois, à traiter au cas par cas plutôt qu'en segment). Le cluster 0, très largement majoritaire (70,50 %, 25 526 clients), correspond bien au profil attendu : rythme et volume de paiement faibles, et une composition dominée par les segments « Utilisateur mixte équilibré », « Cash dominant » et « Cash occasionnel ». Ce cluster confirme donc, pour la majorité du groupe, la lecture d'ensemble d'une activation tardive associée à un engagement plus faible.




FIGURE 6.3 – DBSCAN restreint au groupe « activation tardive » (table 1)

Un second cluster nuance toutefois cette lecture. Le cluster 2 (13,74 %, 4 976 clients) se distingue par une fréquence et un volume de paiement nettement supérieurs à ceux du cluster majoritaire – plus du double en fréquence – et une composition très orientée paiement : environ 85 % de ses membres sont déjà classés « Grand utilisateur multi-usage » ou « Utilisateur paiement dominant » dans la segmentation renforcée du chapitre 5. Autrement dit, l'activation tardive ne se traduit pas systématiquement par un engagement durablement faible : environ un client tardif sur sept a fini par développer un usage carte solide, malgré un démarrage lent. Les trois clusters restants sont de taille beaucoup plus réduite (moins de 6 % de l'effectif à eux trois) et correspondent à des profils plus marginaux – notamment un cluster de clients à relation plus récente et un cluster de très gros volumes atypiques – sans remettre en cause la lecture d'ensemble.

Ce résultat a une implication opérationnelle directe : au sein même du groupe le plus tardif, un sous-segment identifiable (environ 5 000 clients) justifie une action de fidélisation plutôt qu’une action d’activation, puisque l’activation, chez ces clients, a déjà réussi – avec retard, mais durablement.

6.6 Interprétation et limites

Ces résultats suggèrent que la vitesse à laquelle un client réalise son premier paiement après l’ouverture de sa relation est un signal précoce, corrélé à son niveau d’engagement ultérieur avec le paiement carte – un lien confirmé aussi bien par le rythme d’usage que par le taux de désengagement réel. Sur le plan opérationnel, cela renforce l’intérêt d’actions d’accompagnement précoces – dans le mois suivant l’ouverture de la relation – plutôt que des campagnes de relance tardives, dans la mesure où les clients activés tardivement semblent, en moyenne, s’installer durablement dans un profil d’usage plus faible et plus orienté cash. Le DBSCAN restreint à ce groupe nuance néanmoins cette moyenne : une action de relance générique sur l’ensemble des activations tardives risquerait de traiter à l’identique des clients déjà bien engagés et des clients réellement à risque, alors qu’un sous-segment d’environ 5 000 clients relève plutôt d’une logique de fidélisation.

Cette lecture appelle toutefois deux réserves. D’une part, l’analyse reste corrélationnelle : elle ne permet pas de distinguer si l’activation rapide favorise elle-même la fidélité, ou si les deux résultent d’un même profil de client déjà plus engagé au départ. D’autre part, l’exclusion de 5,2% des clients pour délai négatif limite la portée des conclusions et souligne la nécessité de fiabiliser cette variable auprès de la source des données avant toute exploitation commerciale directe.

Conclusion

Ce chapitre a montré qu’une lecture rétrospective simple, construite à partir de deux dates déjà présentes dans les données, suffit à révéler un lien cohérent et exploitable entre vitesse d’activation et fidélité ultérieure. Ce lien se confirme sur un indicateur de désengagement réel et non plus seulement sur un proxy de rythme d’usage, et se retrouve jusque dans le profil des commerçants fréquentés. Le DBSCAN restreint au groupe le plus tardif apporte cependant une nuance utile : derrière une moyenne de groupe défavorable se cache un sous-segment de clients déjà bien engagés, qui appelle une action différente du reste du groupe. Ces pistes viennent compléter la segmentation comportementale présentée au chapitre 5, et pourront être approfondies par un modèle prédictif à part entière si un historique de transactions daté devient disponible.

Chapitre 7

Modélisation prédictive et recommandations

Introduction

Ce chapitre présente les résultats des modèles prédictifs construits à partir des bases préparées au chapitre 4. Il s'ouvre avec le modèle de classification actif / jamais actif, qui correspond au modèle XGBoost annoncé en introduction pour prédire l'inactivité des porteurs de cartes, se poursuit avec un modèle de régression estimant la valeur attendue de chaque client, puis avec le scoring commerçant et deux modèles de survie de Cox – l'un sur le délai avant première activation, l'autre sur le désengagement réel. Il se conclut par les recommandations stratégiques qui consolident l'ensemble de ces résultats en actions opérationnelles.

7.1 Modèle de classification actif / jamais actif

7.1.1 Rappel du protocole

La base d'entraînement, préparée et documentée au chapitre 4, réunit 94 111 clients du marché « PARTICULIER » – 34 111 clients actifs (table 1) et 60 000 clients jamais actifs (table 2) – décrits par sept variables indépendantes du paiement carte : âge, genre, profession, niveau de service, ville, ancienneté et usage digital.

La base a été séparée en un jeu d'entraînement de 75 288 clients et un jeu de test de 18 823 clients, par tirage aléatoire stratifié sur la cible (80 % / 20 %), afin de conserver la même proportion de clients actifs (36,2 %) dans les deux jeux. Le modèle retenu est un classifieur XGBoost [Chen and Guestrin, 2016] (300 arbres, profondeur maximale 5, taux d'apprentissage 0,05), dont la gestion native des variables catégorielles a été utilisée pour les variables profession, niveau de service et ville, afin d'éviter un encodage *one-hot* qui aurait démultiplié le nombre de colonnes sans bénéfice pour ce type de variables à forte cardinalité.

7.1.2 Résultats

Sur le jeu de test, le modèle atteint une exactitude de 89,6 %, une précision de 87,6 %, un rappel de 83,1 %, un F1-score de 85,3 % et une aire sous la courbe ROC de 0,966. Ces résultats sont sensiblement inférieurs à ceux obtenus lors d'un premier essai incluant le marché et les variables de retrait (respectivement 98,2 % et 0,998 d'AUC), mais cet écart est attendu et souhaitable : le premier essai reposait sur des variables biaisées par une différence de périmètre entre les deux tables sources, documentée au chapitre 4, et surestimait artificiellement la performance du modèle. Les résultats présentés ici reflètent un signal prédictif réel, fondé uniquement sur des variables de profil et d'usage digital.

La matrice de confusion montre que le modèle identifie correctement 11 200 des 12 001 clients jamais actifs (93 % de rappel sur cette classe) et 5 671 des 6 822 clients actifs (83 % de rappel). Les erreurs se répartissent en 801 faux positifs – des clients jamais actifs prédits comme actifs – et 1 151 faux négatifs – des clients actifs prédits comme jamais actifs. Le modèle est donc légèrement plus prudent pour repérer les clients actifs que pour écarter les clients jamais actifs, ce qui reste cohérent avec un usage commercial du score : mieux vaut cibler un peu trop large que manquer des clients à fort potentiel.




FIGURE 7.1 – Matrice de confusion du modèle actif / jamais actif (jeu de test)




FIGURE 7.2 – Courbe ROC du modèle actif / jamais actif

7.1.3 Importance des variables

Au-delà des métriques globales de performance, il est utile d'identifier quelles variables pèsent le plus dans les prédictions du modèle, afin de vérifier la cohérence du signal appris avec les constats métier des chapitres précédents.




FIGURE 7.3 – Importance des variables du modèle actif / jamais actif

La ville (32,7 %) et l'usage digital (29,0 %) dominent très largement l'importance des variables, suivies du niveau de service (16,2 %), de la profession (9,2 %), du genre (6,4 %), de l'âge (3,9 %) et de l'ancienneté (2,5 %). La prédominance de l'usage digital est cohérente avec les constats des chapitres précédents : le chapitre 6 avait déjà montré qu'un usage digital plus élevé est associé à un engagement de paiement plus fort, et la table 2 comptait une part significative de clients sans aucune connexion à l'application (segment « Aucune connexion app » de l'*alerte_metier*, chapitre 4). Le poids important de la variable ville, en revanche, suggère un effet géographique – probablement lié à la densité du réseau d'acceptation carte ou à des dynamiques locales d'adoption – qui n'avait pas été investigué dans les chapitres précédents et mériterait une analyse complémentaire dédiée.

7.2 Modèle de régression – valeur attendue

7.2.1 Rappel du protocole

Le modèle précédent indique la probabilité qu'un client de la table 2 s'active un jour, mais ne dit rien de la valeur que représenterait ce client une fois activé : deux clients à probabilité égale peuvent

avoir un potentiel d'usage très différent. Pour compléter cette lecture, nous entraînons un second modèle – une régression, et non plus une classification – qui prédit l'intensité d'usage attendue d'un client à partir de son seul profil.

La cible retenue est le **rythme de paiement mensuel**, déjà construit au chapitre 6 comme le nombre de paiements par mois depuis la première activation : cette mesure neutralise le biais de temps d'exposition plutôt que d'utiliser un total cumulé, qui favoriserait mécaniquement les clients actifs depuis longtemps. Le modèle est entraîné uniquement sur la table 1, restreinte au marché « PARTICULIER » pour rester comparable à la table 2, sur les 34 064 clients disposant à la fois d'un délai d'activation valide et d'un profil complet. Les variables explicatives sont les mêmes sept variables de profil que le modèle de classification, afin de pouvoir appliquer le modèle appris aux clients de la table 2.

7.2.2 Résultats

Sur le jeu de test, le modèle – un régresseur XGBoost aux mêmes hyperparamètres que le classifieur – atteint une erreur quadratique moyenne (RMSE) de 2,57 paiements par mois et une erreur absolue moyenne (MAE) de 1,37, contre respectivement 2,82 et 1,64 pour une prédiction naïve qui se contenterait de la moyenne du jeu d'entraînement pour tous les clients. Le modèle apporte donc un signal réel, mais modeste : le coefficient de détermination (R^2) s'établit à 0,168, ce qui signifie que le profil socio-démographique et l'usage digital n'expliquent qu'une fraction limitée de la variance du rythme d'usage – une bonne part de l'intensité d'usage réelle d'un client tient à des facteurs individuels que ces sept variables ne peuvent pas capturer.

Le nuage de points confirme cette lecture : le modèle resserre ses prédictions autour de valeurs modérées et peine à anticiper les rythmes d'usage les plus élevés, un comportement attendu pour un signal faible – il est plus prudent de prédire une valeur proche de la moyenne que de parier sur un cas extrême rarement observé pour un profil donné.

L'ancienneté relationnelle domine l'importance des variables (25,3 %), suivie de l'usage digital (16,4 %), de la ville (13,7 %), de la profession (13,6 %), du niveau de service (12,5 %), de l'âge (12,0 %) et du genre (6,5 %). Ce classement diffère de celui du modèle de classification, où la ville et l'usage digital dominaient très largement : prédire *si* un client va s'activer et prédire *à quel rythme* il paierait une fois activé ne s'appuient donc pas exactement sur les mêmes leviers.

7.2.3 Score de valeur attendue et priorisation combinée

Le modèle entraîné est appliqué aux 60 000 clients de la table 2 pour produire un score de valeur attendue par client, croisé avec la probabilité d'activation du modèle de classification. La corrélation entre les deux scores est faible et légèrement négative ($r = -0,099$) : un client à forte probabilité d'activation n'est pas plus susceptible d'avoir un fort potentiel d'usage, et inversement. Ce résultat justifie *a posteriori* l'intérêt de croiser les deux scores plutôt que de se fier à un seul : en répartissant les clients selon la médiane de chaque score, quatre groupes de taille comparable se dégagent – 9 452 clients à probabilité et valeur élevées, 20 561 à forte probabilité mais valeur plus faible, 20 555 à l'inverse, et 9 432 aux deux scores faibles. Ces quatre groupes sont directement mobilisés dans les recommandations qui suivent.




FIGURE 7.4 – Valeurs prédites contre valeurs réelles du rythme de paiement mensuel (jeu de test)

7.2.4 Limites

Un R^2 de 0,168 reste modeste : ce modèle donne une indication directionnelle utile pour prioriser des actions à l'échelle de milliers de clients, mais ne doit pas être lu comme une prédiction fiable au niveau d'un client individuel. Cette limite est cohérente avec la nature des variables disponibles : un profil socio-démographique et un niveau d'usage digital renseignent sur le contexte d'un client, mais ne peuvent pas capturer l'ensemble des facteurs qui déterminent son comportement de paiement réel. Un historique transactionnel daté, déjà identifié comme la principale limite de ce mémoire, permettrait probablement d'améliorer sensiblement ce signal.




FIGURE 7.5 – Importance des variables du modèle de régression – valeur attendue

7.3 Scoring commerçant

7.3.1 Rappel de la méthode

Contrairement au modèle précédent, ce volet ne repose pas sur un algorithme entraîné, mais sur un changement de granularité et une agrégation : les clients de la table 1 sont regroupés par leur commerçant de plus forte dépense (*ens_pv_top_depense_2025*), afin de produire un indicateur par commerçant plutôt que par client. La préparation de cette base, détaillée au chapitre 4, a nécessité l’harmonisation des noms de commerçants (12 363 valeurs brutes ramenées à 12 318 commerçants distincts) et l’application d’un seuil de fiabilité de 30 clients minimum, retenant 177 commerçants sur les 19 784 clients qu’ils couvrent.

L’indicateur central retenu est la part de clients classés « Grand utilisateur multi-usage » parmi les clients de chaque commerçant (*pct_grand_utilisateur*), utilisée comme mesure de la qualité de la clientèle attirée plutôt que de l’activité commerciale du point de vente lui-même – cette dernière n’étant pas mesurable avec les données disponibles (voir la limite méthodologique rappelée plus bas).

7.3.2 Résultats

Le commerçant le plus fréquemment désigné est ONCF E-commerce (1 309 clients), suivi de Carrefour Market (1 308) et de Glovo (1 262) – trois enseignes à forte notoriété nationale, ce qui est attendu pour les commerçants les plus cités. La moyenne de *pct_grand_utilisateur* sur l’ensemble

des 177 commerçants fiables s'établit à 13,4 %.

Un résultat se détache nettement de cette moyenne : **Glovo**, avec 1 262 clients, affiche 44 % de « Grands utilisateurs multi-usage » parmi sa clientèle – soit environ 3,3 fois la moyenne des commerçants fiables, et le score le plus élevé de tous les commerçants au-dessus du seuil de fiabilité. Ce résultat est d'autant plus notable que Glovo n'est pas le commerçant avec le montant moyen de paiement le plus élevé (50 619 en moyenne, contre 60 295 pour RAM Internet ou 124 608 pour un commerçant plus restreint comme Resort Co) – la valeur de sa clientèle ne tient donc pas au montant des transactions, mais à la fréquence et à la régularité de l'engagement carte de ses clients.




FIGURE 7.6 – Top 10 des commerçants (échantillon fiable) par part de « Grands utilisateurs multi-usage »

Derrière Glovo, les commerçants les mieux classés sont plus hétérogènes en taille : Resort Co (43 %, 49 clients), Kitea Géant Rabat (36 %, 36 clients) et Sisal Jeux Maroc (32 %, 31 clients) combinent un score élevé à un effectif proche du seuil de fiabilité minimal, ce qui invite à une lecture prudente de leur classement tant que l'échantillon ne grandit pas.

7.3.3 Interprétation et usage

Ce classement offre à la banque un critère objectif pour prioriser ses partenariats commerçants : cibler en priorité les enseignes qui attirent structurellement une clientèle à fort usage du paiement carte, comme Glovo, plutôt que celles qui se contentent d'un grand nombre de clients sans que ceux-ci soient particulièrement engagés dans le paiement (à l'image d'ONCF E-commerce, très cité mais avec seulement 17 % de grands utilisateurs). Un partenariat ciblé – mise en avant, offre de cashback – avec

ce type de commerçant pourrait constituer un levier d’activation pour des clients au profil proche mais non encore engagés dans le paiement carte.

Il convient toutefois de rappeler la limite méthodologique déjà soulignée au chapitre 4 : ce score mesure la valeur de la clientèle qui désigne un commerçant comme sa destination principale, et non le chiffre d’affaires réellement encaissé par ce commerçant, faute de détail transactionnel par commerçant dans les données disponibles.

7.4 Modèle de survie – délai avant première activation

7.4.1 Rappel du protocole

Ce premier modèle de survie s’intéresse au temps écoulé jusqu’à la première activation carte, avant d’être complété plus loin dans ce chapitre par un second modèle de survie portant sur le désengagement réel, rendu possible par une donnée obtenue en cours de projet. Les deux modèles reposent sur le modèle de Cox à risques proportionnels [Cox, 1972], ajusté à l’aide de la bibliothèque Python *lifelines* [Davidson-Pilon, 2019]. La table 1 fournit les événements observés (durée = délai entre le début de la relation et le premier paiement), la table 2 fournit les observations censurées (durée = ancienneté actuelle, l’activation n’ayant pas encore eu lieu). Après restriction au marché « PARTICULIER » – la même contrainte de périmètre que pour le modèle actif / jamais actif –, la base réunit 94 063 clients, dont 34 064 événements observés et 59 999 observations censurées.

7.4.2 D’un modèle simple à un modèle stratifié

Un premier modèle, incluant genre, niveau de service, âge et usage digital comme covariables, converge sans difficulté (concordance de 0,790) mais présente deux limites. D’une part, la vérification de l’hypothèse des risques proportionnels – qui suppose que l’effet de chaque variable sur le risque d’activation reste constant dans le temps – échoue pour le genre et plusieurs niveaux de service. D’autre part, l’ajout de la profession et de la ville comme covariables supplémentaires, pourtant regroupées en catégories moins nombreuses, provoque une non-convergence : le temps d’ajustement dépasse dix minutes sans stabilisation, signe d’une séparation quasi parfaite sur certaines catégories rares.

Nous résolvons les deux problèmes par la **stratification** plutôt que par un simple renforcement de la pénalisation. Une variable placée en strate ne reçoit pas de coefficient : chaque modalité dispose de sa propre fonction de risque de base, ce qui neutralise à la fois le risque de séparation et l’obligation de vérifier la proportionnalité pour cette variable, puisqu’elle sort du terme linéaire du modèle. Stratifier les quatre variables catégorielles simultanément aurait toutefois produit 8 143 combinaisons observées, avec une moyenne de 4 événements par combinaison – bien trop fragmenté pour être exploitable. Nous stratifions donc uniquement le genre et le niveau de service (38 combinaisons, environ 900 événements chacune), ce qui permet à la profession et à la ville de redevenir des covariables classiques, cette fois sans concurrencer genre et niveau de service dans l’optimisation : le modèle converge alors normalement.

7.4.3 Résultats

Le modèle stratifié atteint une concordance de 0,766, légèrement inférieure au modèle initial – la contrepartie attendue de sortir genre et niveau de service du terme linéaire. En échange, la profession et la ville deviennent des covariables interprétables : sur 70 modalités encodées, 50 sont statistiquement significatives, une richesse d’information qu’aucun des modèles précédents n’apportait.

Plusieurs professions se distinguent nettement. Les profils étudiants et cadres activent plus rapidement que la référence : « Étudiant de l’enseignement supérieur » (hazard ratio de 1,44), « Ingénieur d’État » (1,29), « Étudiant chercheur » (1,25), « Étudiant » (1,22) et « Cadre » (1,19). À l’inverse, les profils « Makhzni » (0,73), « Ouvrier » (0,78), « Ouvrier non qualifié » (0,79) et « Femme au foyer » (0,82) activent nettement plus lentement. Côté géographique, plusieurs villes ressortent avec un hazard ratio supérieur à 1,15 : Témara (1,32), Salé (1,22), Mohammedia (1,21), Settat (1,21) et Marrakech (1,18), tandis que les clients sans ville renseignée activent plus lentement (0,85).

Ce résultat éclaire en partie un constat resté sans explication au chapitre précédent : la ville était la variable la plus importante du modèle de classification actif / jamais actif, sans que sa nature exacte soit connue. Le modèle de survie confirme qu’il s’agit d’un effet géographique réel plutôt que diffus – quelques villes précises se distinguent nettement des autres –, mais son interprétation exacte appelle une réserve importante, détaillée dans la section Limites ci-dessous : le hazard ratio d’une ville ne mesure pas uniquement une vitesse d’activation.

Cette différence de vitesse par profession ne se limite pas au seul délai d’activation : un rapprochement avec les résultats du chapitre 6 montre que les professions qui activent le plus vite conservent aussi, une fois activées, un engagement nettement supérieur à la moyenne. Les clients des professions à hazard ratio élevé (étudiants, cadre, ingénieur d’État) ont un âge moyen de 31,7 ans contre 39,4 ans pour l’ensemble de la table 1, un rythme de paiement mensuel médian de 1,19 contre 0,68, et 20,8 % d’entre eux appartiennent au segment « Grand utilisateur multi-usage » contre 14,2 % en moyenne. À l’inverse, les professions les plus lentes (Makhzni, Ouvrier, Ouvrier non qualifié, Femme au foyer) affichent un âge moyen de 50,3 ans et seulement 6,3 % de « Grand utilisateur multi-usage » – moins de la moitié de la moyenne. La vitesse d’activation par profession n’est donc pas un simple signal précoce isolé : elle annonce aussi, dans ces données, la qualité de l’engagement ultérieur.

7.4.4 Limites

La vérification de l’hypothèse des risques proportionnels sur ce modèle stratifié signale 33 variables en violation, y compris l’âge, l’usage digital et la plupart des professions. Cette proportion élevée ne traduit pas une dégradation du modèle par rapport à la version précédente, mais une propriété connue du test de Schoenfeld : à grand échantillon – 94 063 lignes ici –, le test devient extrêmement sensible et signale des écarts à la proportionnalité même minimes et sans portée pratique, comme le rappelle d’ailleurs la documentation de la librairie utilisée. Les coefficients obtenus restent donc valides comme effets moyens sur la période d’observation, mais ne doivent pas être lus comme des effets strictement constants dans le temps. Une piste d’amélioration, non mise en œuvre ici faute de temps, consisterait à stratifier également l’âge après regroupement en classes.

Une seconde réserve, plus spécifique à la ville, mérite d’être détaillée. Le modèle combine, pour estimer le risque de chaque ville, les clients de la table 1 qui ont activé (délai observé) et les clients de




FIGURE 7.7 – Modèle de survie – variables au plus fort effet sur la vitesse d’activation

la table 2 qui ne l’ont jamais fait (durée censurée = ancienneté actuelle) : le hazard ratio d’une ville reflète donc un mélange entre deux effets distincts, la vitesse d’activation proprement dite et la part de clients qui ne s’activent jamais. Un contrôle direct sur les délais bruts illustre cette limite : parmi les clients de la table 1 de Témara (hazard ratio de 1,32, la ville la plus « rapide » du modèle), le délai médian réel avant activation est de 427,5 jours – le plus long des six villes examinées, plus long que celui de Casablanca (358,5 jours), pourtant classée plus lente (hazard ratio de 0,92). L’écart s’explique par la part de clients qui n’activent jamais : elle atteint 64,4 % à Casablanca contre seulement 17,6 % à Témara. Le modèle capte donc bien un effet géographique réel et statistiquement robuste – la vérification de proportionnalité ne signale d’ailleurs pas de problème sur la variable ville de Témara elle-même –, mais cet effet doit être lu comme « la probabilité qu’un client de cette ville finisse par activer un jour » plutôt que comme « la vitesse à laquelle il le fait ». Cette nuance limite la portée du parallèle établi plus haut avec l’effet ville du modèle de classification actif / jamais actif, et invite à la prudence avant toute action commerciale qui présupposerait un simple effet de rapidité.

7.5 Modèle de survie – désengagement réel

7.5.1 Rappel du protocole

Comme annoncé au chapitre 4, l’encadrant entreprise a transmis en cours de projet une extraction complémentaire fournissant la date de dernier paiement de chaque client de la table 1, à une date

de référence du 31 décembre 2025. Cette donnée permet de construire, pour la première fois dans ce mémoire, un véritable événement de désengagement – non plus une reformulation fautive de mieux, mais la cible initialement visée. Un client est considéré désengagé si son dernier paiement remonte à plus de 120 jours à la date de référence (seuil déterminé empiriquement, voir chapitre 4), et censuré sinon. La durée de survie est mesurée entre la première activation et l'événement (ou la censure).

7.5.2 D'un modèle exploratoire à un modèle affiné

Une première spécification, reprenant la recette du modèle d'activation (profession et ville en covariables), donne une concordance faible de 0,608, avec seulement 3 variables significatives sur 49 et des hazard ratios négligeables : contrairement à l'activation, le désengagement d'un client déjà actif ne semble guère expliqué par sa profession ou sa ville. L'exploration de plusieurs variantes montre que deux variables jusque-là absentes du modèle – le **marché** et l'**ancienneté relationnelle** – apportent un signal nettement plus informatif, tandis que profession et ville, à l'inverse, n'apportent presque rien : une fois ces deux dimensions substituées, la concordance atteint 0,72 avec beaucoup moins de covariables.

Le modèle est enfin restreint au marché « PARTICULIER », pour rester cohérent avec le périmètre des autres modèles de ce chapitre et pour disposer d'une population homogène directement mobilisable dans les recommandations commerciales. La base finale réunit 33 885 clients, dont 3 513 désengagements observés (10,4 %) et 30 372 censures.

7.5.3 Résultats

Le modèle retenu – niveau de service, genre, âge, usage digital et ancienneté comme covariables, sans stratification – atteint une **concordance de 0,7205**, avec 7 variables significatives sur 19. Les hazard ratios sont exprimés par rapport à la catégorie de niveau de service la plus fréquente (« S3 – Potentiel », 8 839 clients), plutôt que par rapport à un regroupement résiduel peu interprétable.

Le niveau de service ressort comme le facteur le plus structurant : les segments haut de gamme se désengagent moins que la référence – « S1 – Excellence » (hazard ratio de 0,91) et « S2 – Premium » (0,94) –, tandis que les segments plus larges se désengagent davantage – « S5 – Universel » (1,05) et surtout « S6 – Lib » (1,08). Les trois covariables numériques ont un effet réel mais modeste une fois ramené à une échelle lisible : chaque année d'ancienneté supplémentaire réduit le risque de désengagement d'environ 0,5 %, chaque tranche de 100 connexions à l'application d'environ 0,7 %, et chaque décennie d'âge d'environ 1,5 %.

7.5.4 Limites

Deux réserves, dans la continuité de celles déjà posées pour le modèle d'activation. D'une part, la vérification de l'hypothèse des risques proportionnels signale l'âge, l'ancienneté et le niveau de service « Lib » en violation – la même sensibilité du test de Schoenfeld à grand échantillon déjà rencontrée précédemment, qui n'invalide pas les coefficients mais invite à les lire comme des effets moyens plutôt que strictement constants dans le temps. D'autre part, l'interprétation précise de chaque niveau de service (par exemple ce qui distingue concrètement « Universel » de « Lib ») repose sur une nomenclature interne à la banque, que ce mémoire n'a pas vocation à documenter en détail : la lecture retenue ici – un gradient du plus haut de gamme au plus grand public – est cohérente avec le sens des hazard ratios observés, mais gagnerait à être confirmée avec l'entité Data BDME.




FIGURE 7.8 – Modèle de survie – désengagement réel (marché particulier), variables significatives

7.6 Recommandations stratégiques

Cette dernière section consolide les résultats du chapitre 5 et des sections précédentes de ce chapitre en recommandations opérationnelles, à destination de l'entité Data BDME et des équipes marketing d'Attijariwafa bank.

7.6.1 Prioriser l'activation par un score combiné probabilité $\times$ valeur

Le modèle actif / jamais actif fournit, pour chaque client de la table 2, une probabilité d'activation ; le modèle de régression fournit, pour ce même client, une valeur attendue – l'intensité d'usage qu'il produirait s'il s'activait. La faible corrélation observée entre ces deux scores ($r = -0,099$) confirme qu'ils apportent une information complémentaire plutôt que redondante, et le croisement des deux médianes fait ressortir quatre groupes de taille comparable : 9 452 clients à probabilité et valeur élevées – la cible prioritaire, où l'effort commercial produit le meilleur retour attendu ; 20 561 clients à forte probabilité mais valeur plus faible, où une activation est probable mais peu rentable en elle-même ; 20 555 clients à l'inverse, à fort potentiel de valeur mais probabilité d'activation plus faible, qui justifient un accompagnement plus soutenu pour convertir un potentiel réel en activation effective ; et 9 432 clients aux deux scores faibles, à traiter en priorité basse. Le modèle de survie vient ensuite affiner le calendrier de ces actions : à profil comparable, les hazard ratios du chapitre précédent indiquent quels clients sont susceptibles de répondre rapidement (par exemple un profil « Cadre », hazard ratio de 1,19) et lesquels nécessitent une relance plus étalée dans le temps (un profil « Ouvrier », hazard ratio de 0,78).

7.6.2 Accompagner les nouveaux clients dans le premier mois

Le chapitre 6 a montré qu'un client activé dans les 30 premiers jours suivant l'ouverture de sa relation affiche, par la suite, un rythme de paiement mensuel médian environ trois fois supérieur à un client activé après 60 jours (1,66 contre 0,55 paiement par mois), et une probabilité environ 1,5 fois plus élevée de devenir « Grand utilisateur multi-usage » (20,65 % contre 13,44 %). Nous recommandons de concentrer les actions d'accompagnement à l'ouverture de compte – prise en main de la carte, sensibilisation au paiement sans contact, activation de l'application – sur le premier mois de la relation, plutôt que sur des campagnes de relance plus tardives et, d'après ce constat, structurellement moins efficaces.

7.6.3 Cibler les partenariats commerçants à forte valeur de clientèle

Le scoring commerçant présenté plus haut dans ce chapitre identifie Glovo comme le commerçant associé à la clientèle la plus engagée dans le paiement carte (44 % de « Grands utilisateurs multi-usage » parmi ses clients, contre 13,4 % en moyenne sur les 177 commerçants fiables), sans que cela corresponde au montant moyen de paiement le plus élevé. Nous recommandons de prioriser ce type de partenaire – à forte fréquence d'usage plutôt qu'à fort montant unitaire – pour des opérations de cashback ou de mise en avant ciblées sur les clients de la table 2 dont le profil se rapproche des grands utilisateurs déjà identifiés, dans une logique d'acquisition par affinité commerçant plutôt que par seul volume de sollicitation.

7.6.4 Différencier les actions par segment comportemental

La segmentation renforcée du chapitre 5 distingue, sur la table 2, des sous-populations aux besoins différents : les clients « Profil cash à convertir » (6 625 clients) disposent déjà d'un usage cash établi et constituent une cible de conversion vers le paiement carte, tandis que les clients « Cible à activer avec accompagnement » (3 129 clients) nécessitent un travail plus en amont sur l'adoption elle-même. Sur la table 1, les clients déjà classés « Grand utilisateur multi-usage » justifient à l'inverse des actions de fidélisation et de reconnaissance plutôt que d'activation, afin de préserver un comportement déjà favorable. Nous recommandons de décliner des parcours marketing distincts par segment, plutôt qu'une communication uniforme, en s'appuyant sur les profils déjà caractérisés au chapitre 5.

7.6.5 Adapter la communication aux profils démographiques et géographiques

Le modèle de survie fait ressortir des écarts marqués de vitesse d'activation selon la profession. Les profils étudiants et cadres s'activent nettement plus vite que la moyenne, tandis que les profils ouvriers, « Femme au foyer » et « Makhzni »¹ s'activent plus lentement – un écart qui, comme montré plus haut, se prolonge au-delà de l'activation elle-même sur la qualité d'engagement ultérieur. Nous recommandons d'adapter le ton et le canal des campagnes à ces profils : une communication digitale et autonome pour les profils rapides, déjà réceptifs, et un accompagnement plus humain – en agence ou par contact direct – pour les profils plus lents, dont le frein tient probablement moins à l'intérêt pour le produit qu'à l'accès ou à l'habitude d'usage.

1. Membre des Forces auxiliaires, un corps paramilitaire marocain placé sous l'autorité du ministère de l'Intérieur.

Côté géographique, l'effet mesuré par le modèle appelle une lecture différente : comme détaillé à la section Limites ci-dessus, le hazard ratio d'une ville reflète surtout la part de ses clients qui finissent, ou non, par activer un jour, plutôt qu'une vitesse d'activation à proprement parler. Des villes comme Casablanca, où 64,4 % des clients ne s'activent jamais, représentent donc un gisement de conversion bien plus large que des villes comme Témara, où cette part tombe à 17,6 %. Nous recommandons de prioriser les actions de conversion sur les zones à forte population jamais-active plutôt que d'y voir un simple retard de vitesse à corriger par un accompagnement renforcé – la cause sous-jacente de cet écart (densité du réseau d'acceptation carte, dynamiques locales d'adoption) reste néanmoins hors du périmètre des données disponibles pour ce projet.

7.6.6 Prévenir le désengagement selon le niveau de service

Le modèle de survie sur le désengagement réel montre que le risque n'est pas réparti uniformément : les clients des segments « Excellence » et « Premium » se désengagent nettement moins que la moyenne, tandis que les segments « Universel » et surtout « Lib » présentent un risque plus élevé. Nous recommandons de mettre en place un suivi de rétention proactif ciblé sur ces derniers segments – par exemple une alerte commerciale dès qu'un client dépasse 90 jours sans paiement carte, avant que le seuil de désengagement de 120 jours ne soit atteint – plutôt qu'un traitement uniforme de la base active, qui traiterait de la même façon des clients à risque très différent.

Conclusion

Le modèle de classification actif / jamais actif obtient une performance solide (AUC 0,966) à partir de variables de profil et d'usage digital, sans dépendre d'aucune information liée au paiement carte lui-même. La vérification méthodologique effectuée pour écarter les variables biaisées par le périmètre des deux tables sources a été déterminante pour la validité de ce résultat, et souligne l'importance de ne pas se fier à une performance apparemment excellente sans en vérifier l'origine. Le modèle de régression qui lui succède complète cette probabilité par une estimation de la valeur attendue de chaque client ; son signal est plus modeste ($R^2 = 0,168$) mais réel, et la faible corrélation entre les deux scores confirme qu'ils éclairent deux dimensions distinctes du potentiel client.

Le scoring commerçant complète cette lecture par un angle différent, non plus centré sur le client mais sur les partenaires commerciaux : il fait ressortir Glovo comme un commerçant associé à une clientèle nettement plus engagée dans le paiement carte que la moyenne, un critère directement exploitable pour prioriser des actions de partenariat. Les deux modèles de survie apportent enfin une lecture temporelle que les modèles précédents n'offraient pas : le premier explique en partie l'effet de la ville déjà observé dans le modèle actif / jamais actif (certaines villes précises accélèrent nettement l'activation, de même que les profils étudiants et cadres) ; le second, rendu possible par une donnée obtenue en cours de projet, montre que le désengagement des clients déjà actifs dépend surtout de leur niveau de service, avec un signal plus modeste (concordance de 0,72) que pour l'activation.

Ces cinq modèles, mis en regard des segmentations du chapitre 5 et de l'étude rétrospective du chapitre 6, ont permis de formuler six recommandations opérationnelles concrètes : la priorisation par score combiné probabilité / valeur, l'accompagnement précoce dans le premier mois, le ciblage de partenariats commerçants à forte valeur de clientèle, la différenciation des actions par segment comportemental, l'adaptation de la communication aux profils démographiques et géographiques les

plus lents à s'activer, et la prévention du désengagement ciblée sur les segments de service à risque.

Conclusion générale & Perspectives

Ce projet de fin d'études nous a permis de concevoir une stratégie data-driven complète pour augmenter le volume et la fréquence d'usage des cartes de paiement au sein d'Attijariwafa bank, en suivant la méthodologie CRISP-DM du cadrage initial jusqu'aux recommandations opérationnelles.

Sur le plan méthodologique, nous avons d'abord construit une compréhension fine des deux populations de clients mises à disposition – les porteurs déjà actifs sur le paiement carte et ceux qui ne l'ont jamais utilisé – puis enrichi la segmentation métier existante par des méthodes non supervisées (K-Means, DBSCAN, réduction de dimension), qui ont confirmé la robustesse des segments les plus structurants tout en révélant des profils invisibles pour une lecture par seuils. Cette base a ensuite servi à cinq modèles complémentaires : une étude rétrospective démontrant qu'une activation rapide est associée à une fidélité ultérieure nettement plus forte, un classifieur XGBoost distinguant les clients actifs des jamais-actifs avec une performance solide (AUC de 0,966) à partir de variables de profil seules, un modèle de régression estimant la valeur attendue de chaque client jamais actif, un modèle de survie de Cox détaillant l'effet différencié de la profession et de la ville sur la vitesse d'activation, et un second modèle de survie portant cette fois sur le désengagement réel des clients déjà actifs, rendu possible par une donnée obtenue en cours de projet. Un scoring commerçant est venu compléter cette lecture centrée client par un angle partenarial. L'ensemble de ces résultats s'est traduit en six recommandations opérationnelles concrètes, allant de la priorisation des clients à la prévention du désengagement selon le niveau de service.

Ce travail confirme, à l'échelle de ce projet, l'intérêt d'une approche data-driven pour une banque comme Attijariwafa : elle permet de passer d'une gestion uniforme et réactive de l'activation des cartes – telle que décrite au chapitre 1 – à un ciblage différencié et anticipé, fondé sur des signaux mesurables plutôt que sur la seule intuition métier. Dans un secteur bancaire marocain en pleine transformation digitale, où l'usage de la carte reste un levier direct de rentabilité et de fidélisation, la capacité à identifier tôt les clients à fort potentiel – et à adapter l'action commerciale à leur profil réel – représente un avantage opérationnel mesurable, aussi bien en efficacité marketing qu'en allocation des ressources commerciales.

Plusieurs pistes restent toutefois ouvertes pour approfondir ce travail. La limite la plus structurante identifiée en début de projet était l'absence de données transactionnelles datées : les tables mises à disposition ne fournissaient que des agrégats (totaux, moyennes) sur toute la période d'observation, sans historique par client permettant de dater un événement précis. Une donnée plus légère qu'un historique complet – la seule date de dernier paiement de chaque client, combinée à un seuil d'inactivité déterminé empiriquement – a finalement été obtenue en cours de projet, ce qui a permis de construire un véritable modèle de survie du désengagement (chapitre 7) plutôt que de se limiter à documenter cette limite comme initialement prévu. Un historique transactionnel complet resterait néanmoins utile pour lever les limites qui subsistent : construire un véritable modèle prédictif d'activation à J+30 comme initialement envisagé, plutôt que l'étude rétrospective présentée au chapitre 6 ; et introduire des covariables dépendantes du temps dans les deux modèles de survie, ce qui permettrait de re-tester rigoureusement l'hypothèse des risques proportionnels plutôt que de la contourner par stratification ou par une lecture en effets moyens.

D'autres prolongements, moins conditionnés par la disponibilité de nouvelles données, renforceraient également la valeur opérationnelle des recommandations. Un historique des sollicitations marketing déjà envoyées aux clients permettrait de distinguer l'effet réel des actions commerciales d'un simple effet de profil, et d'évaluer par un protocole de test contrôlé (A/B testing) l'impact réel

des recommandations proposées avant un déploiement à grande échelle. Le détail transactionnel par commerçant – plutôt que le seul commerçant de plus forte dépense par client – affinerait le scoring commerçant en une mesure directe du chiffre d'affaires généré, plutôt qu'un indicateur de qualité de clientèle. Le modèle de régression pourrait par ailleurs être affiné par des variables supplémentaires si elles devenaient disponibles : son signal actuel ($R^2 = 0,168$) reste modeste, et un historique transactionnel daté serait, là aussi, le levier le plus direct pour l'améliorer. Enfin, l'effet marqué de la ville, mis en évidence à la fois par le modèle de classification et par le modèle de survie sans être pleinement expliqué, mériterait une analyse dédiée croisant ces résultats avec la densité du réseau d'acceptation carte ou des indicateurs socio-économiques locaux.

Au-delà de ses résultats propres, ce projet illustre plus largement pourquoi la donnée doit devenir un levier stratégique pour la banque : elle seule permet de passer d'une action commerciale appliquée uniformément à l'ensemble de la base clients à une action différenciée, mesurable et améliorable dans le temps – une démarche que l'entité Data BDME pourra poursuivre et affiner à mesure que de nouvelles données deviendront disponibles.

Bibliographie

- [Chapman et al., 2000] Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). CRISP-DM 1.0 : Step-by-step data mining guide. Technical report, SPSS Inc.
- [Chen and Guestrin, 2016] Chen, T. and Guestrin, C. (2016). XGBoost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM.
- [Cox, 1972] Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society : Series B (Methodological)*, 34(2) :187–202.
- [Davidson-Pilon, 2019] Davidson-Pilon, C. (2019). lifelines : survival analysis in Python. *Journal of Open Source Software*, 4(40) :1317.
- [Ester et al., 1996] Ester, M., Kriegel, H.-P., Sander, J., and Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, pages 226–231. AAAI Press.
- [Hubert and Arabie, 1985] Hubert, L. and Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1) :193–218.
- [MacQueen, 1967] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297. University of California Press.
- [McInnes et al., 2018] McInnes, L., Healy, J., and Melville, J. (2018). UMAP : Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv :1802.03426*.
- [McKinney, 2010] McKinney, W. (2010). Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61.
- [Pearson, 1901] Pearson, K. (1901). On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11) :559–572.